



BÁO CÁO TIỂU LUẬN KHÓA LUẬN

MÔN HỌC: GIẢI THUẬT NÂNG CAO

ĐỀ TÀI CHUYÊN SÂU:

**NGHIÊN CỨU VỀ THUẬT TOÁN ZERO-DCE:
TĂNG CƯỜNG ẢNH THIẾU SÁNG BẰNG PHƯƠNG PHÁP
ƯỚC LƯỢNG ĐƯỜNG CONG KHÔNG THAM CHIỀU VÀ CÁC
THỂ NGHIỆM**

Sinh viên thực hiện:	Đỗ Hữu Khang
Lớp:	KHOA HỌC MÁY TÍNH
Mã số sinh viên:	2580101060
Giảng viên hướng dẫn:	Trần Lê Anh

Mục lục

1	Giới thiệu chi tiết và Tầm quan trọng của Đề tài	5
1.1	Tầm quan trọng của Tăng cường Ảnh Thiếu sáng trong Kỹ nguyên Số . . .	5
1.2	Cơ chế sinh lý học thị giác và Cơ chế nhiễu cảm biến vật lý	5
1.2.1	Thị giác bóng tối ở người (Scotopic Vision)	6
1.2.2	Cơ chế nhiễu cảm biến vật lý (Sensor Noise Mechanics)	6
1.3	Các lĩnh vực ứng dụng thực tế quan trọng	6
1.4	Bố cục của Báo cáo Nghiên cứu	7
2	Các công trình liên quan và Phân tích Lịch sử	8
2.1	Phương pháp xử lý ảnh trong miền không gian (Spatial Domain Methods)	8
2.1.1	Cân bằng lược đồ xám toàn cục (Global Histogram Equalization - GHE)	8
2.1.2	Cân bằng lược đồ xám thích ứng giới hạn tương phản (Contrast Limited Adaptive Histogram Equalization - CLAHE)	8
2.2	Lý thuyết Retinex và Các biến thể miền tần số (Frequency Domain Methods)	9
2.2.1	Lý thuyết Retinex đơn tỷ lệ (Single-Scale Retinex - SSR)	9
2.2.2	Lý thuyết Retinex đa tỷ lệ (Multi-Scale Retinex - MSR) và MSRCR	10
2.2.3	Phương pháp ước lượng bản đồ chiếu sáng tối ưu hóa và LIME .	10
2.3	Các phương pháp dựa trên Học sâu (Deep Learning Methods)	11
2.3.1	Học sâu có giám sát (Supervised Deep Learning)	11
2.3.2	Học sâu không giám sát dựa trên mạng GAN (Unsupervised GANs)	11
2.3.3	Học sâu không tham chiếu (Zero-Reference Deep Learning) . . .	11
3	Kiến trúc Hệ thống và Cơ sở Lý thuyết của Zero-DCE	13
3.1	Thiết kế Đường cong Tăng cường Ánh sáng phi tuyến thích ứng (LE-curve)	13
3.1.1	Phương trình toán học cơ bản và Ý nghĩa vật lý	13
3.1.2	Chứng minh toán học chặt chẽ về tính đơn điệu và tính bị chặn của LE-curve	14
3.1.3	Thiết kế đường cong lặp bậc cao thích ứng (Higher-Order Curves)	15
3.1.4	Ví dụ minh họa chi tiết quá trình tăng cường điểm ảnh	15
3.2	Kiến trúc mạng ước lượng tham số DCE-Net	17
3.2.1	Cấu trúc chi tiết các lớp mạng và Skip Connections	17
4	Phân tích Chuyên sâu về Bộ bốn Hàm Mất mát Không Tham chiếu	19
4.1	Hàm mất mát nhất quán không gian (Spatial Consistency Loss - L_{spa}) . .	19

4.2	Hàm mất mát kiểm soát phơi sáng (Exposure Control Loss - L_{exp})	19
4.3	Hàm mất mát hằng số màu sắc (Color Constancy Loss - L_{col})	20
4.4	Hàm mất mát độ mượt ánh sáng (Illumination Smoothness Loss - L_{tv}) . .	21
4.5	Tỷ lệ kết hợp các hàm mất mát	21
5	Quy trình Huấn luyện Mô hình	23
5.1	Chuẩn bị dữ liệu (Data Preparation)	23
5.2	Quá trình lan truyền xuôi (Forward Pass)	23
5.3	Đánh giá chất lượng bằng Bộ bốn Hàm mất mát không tham chiếu	23
5.4	Cập nhật trọng số bằng Lan truyền ngược (Backpropagation)	24
6	Kết quả Thực nghiệm, Bảng số liệu và Thảo luận chuyên sâu	25
6.1	Đánh giá Định lượng trên các tập dữ liệu tiêu chuẩn	25
6.2	Đánh giá Định tính và Trực quan hình ảnh	26
6.3	Tốc độ xử lý và Khả năng đáp ứng thời gian thực	26
6.4	Phân tích Đạo hàm và Khả năng hội tụ toán học của mô hình	27
6.5	Khảo sát các trường hợp thất bại khách quan (Failure Cases Analysis) . .	27
7	Ứng dụng Thực tế và Các bài toán Hạ nguồn	29
7.1	Tác động tích cực đến các bài toán thị giác máy tính hạ nguồn (Down-stream Tasks)	29
7.2	Triển khai tối ưu hóa thời gian thực trên Thiết bị biên (Edge Devices) . .	29
8	Kết luận và Hướng phát triển Tương lai	31
8.1	Tổng kết những đóng góp của báo cáo nghiên cứu	31
8.2	Đề xuất các hướng nghiên cứu mở rộng trong tương lai	31

Danh sách bảng

1	Bảng so sánh tổng quan các nhóm phương pháp tăng cường ảnh thiếu sáng	12
2	Đánh giá định lượng (PSNR/SSIM trên tập LOL; chỉ số NIQE trung bình trên 4 tập dữ liệu không tham chiếu LIME, MEF, DICM, VV)	25
3	So sánh tốc độ xử lý (Frame Per Second - FPS) trên các phần cứng khác nhau	26

Tóm tắt nội dung

Tăng cường hình ảnh trong điều kiện thiếu sáng (Low-Light Image Enhancement - LLIE) là một thách thức quan trọng và lâu đời trong lĩnh vực thị giác máy tính cũng như xử lý ảnh kỹ thuật số. Các phương pháp học sâu truyền thống thường dựa trên việc huấn luyện có giám sát (supervised learning) với các cặp hình ảnh thiếu sáng và ảnh chuẩn (ground-truth) có độ phơi sáng hoàn hảo. Tuy nhiên, trong thực tế, việc thu thập các cặp dữ liệu tính này vô cùng khó khăn, tốn kém và thường dễ bị lệch điểm ảnh do các chuyển động rung lắc nhẹ của camera hoặc sự thay đổi của vật thể trong khung hình.

Bài báo cáo nghiên cứu này trình bày chi tiết và toàn diện về thuật toán **Zero-DCE** (Zero-Reference Deep Curve Estimation), một phương pháp tiếp cận không giám sát đột phá giải quyết bài toán tăng cường ánh sáng mà không cần bất kỳ hình ảnh tham chiếu nào trong quá trình huấn luyện. Triết lý thiết kế của Zero-DCE coi bài toán tăng cường phơi sáng là bài toán ước lượng các đường cong điều chỉnh ánh sáng đặc thù cho từng điểm ảnh (pixel-wise light enhancement curves - LE-curves) thông qua một mạng thần kinh tích chập siêu nhẹ mang tên **DCE-Net**.

Trong báo cáo này, chúng tôi phân tích sâu sắc cơ sở lý thuyết toán học của các đường cong tăng cường, kiến trúc mạng FCN đối xứng, và bộ bốn hàm mất mát không tham chiếu (nhất quán không gian, kiểm soát phơi sáng, hằng số màu sắc và độ mượt ánh sáng).

Kết quả thực nghiệm cho thấy Zero-DCE đạt được hiệu suất vượt trội về cả chất lượng cảm quan lẫn tốc độ xử lý (đạt tới 500 FPS trên GPU phổ thông), mở ra triển vọng ứng dụng thời gian thực trên các thiết bị di động và các hệ thống biên tự hành.

1 Giới thiệu chi tiết và Tầm quan trọng của Đề tài

1.1 Tầm quan trọng của Tăng cường Ảnh Thiếu sáng trong Kỹ nguyên Số

Trong thế kỷ 21, thị giác máy tính và trí tuệ nhân tạo đã trở thành những trụ cột cốt lõi của cuộc Cách mạng Công nghiệp 4.0. Từ camera giám sát thông minh, xe tự hành, máy bay không người lái (drones), cho đến chẩn đoán hình ảnh y khoa và nhiếp ảnh điện toán trên điện thoại thông minh, tất cả đều phụ thuộc hoàn toàn vào chất lượng của dữ liệu hình ảnh đầu vào. Tuy nhiên, việc thu nhận hình ảnh trong điều kiện ánh sáng yếu (như ban đêm, trong nhà, trong các đường hầm hoặc môi trường có độ tương phản phức tạp) luôn là một rào cản kỹ thuật rất lớn đối với các cảm biến quang học hiện đại.

Khi ánh sáng môi trường không đủ, hình ảnh thu được thường bị suy giảm chất lượng nghiêm trọng với các biểu hiện phổ biến bao gồm:

- **Độ tương phản cực thấp:** Phần lớn các chi tiết quan trọng bị chìm vào bóng tối sâu (underexposure), làm mất đi các ranh giới cấu trúc của vật thể.
- **Nhiều hạt và nhiễu màu mạnh (High Noise level):** Để thu được ánh sáng yếu, các cảm biến phải đẩy độ nhạy sáng (ISO) lên rất cao. Điều này vô tình khuếch đại các dòng điện nhiễu nhiệt và nhiễu đọc bên trong cảm biến vật lý, tạo ra vô số đốm hạt nhiễu làm mờ nhạt chi tiết.
- **Sai lệch màu sắc nghiêm trọng (Color Distortion):** Tỷ lệ tín hiệu trên nhiễu (SNR) thấp làm cho cảm biến không ghi nhận chính xác phổ màu của ánh sáng phản xạ, dẫn đến hiện tượng sai tông màu, mất bão hòa màu hoặc ám màu nặng.

Việc nghiên cứu các giải pháp tăng cường ảnh thiếu sáng không đơn thuần phục vụ nhu cầu thẩm mỹ cho cá nhân, mà đóng vai trò sống còn trong việc nâng cao độ tin cậy của các hệ thống AI hạ nguồn (downstream tasks) như phát hiện vật thể (object detection), phân vùng ngữ cảnh (semantic segmentation) và nhận diện khuôn mặt trong điều kiện thiếu sáng.

1.2 Cơ chế sinh lý học thị giác và Cơ chế nhiễu cảm biến vật lý

Để hiểu rõ tại sao bài toán tăng cường ánh sáng lại thách thức như vậy, chúng ta cần tìm hiểu sâu về hai khía cạnh: sinh lý học thị giác con người và vật lý học cảm biến hình ảnh kỹ thuật số.

1.2.1 Thị giác bóng tối ở người (Scotopic Vision)

Hệ thống thị giác của con người sử dụng hai loại tế bào thụ cảm ánh sáng trên võng mạc: tế bào nón (cone cells) chịu trách nhiệm cho thị giác ban ngày (photopic vision) và nhận diện màu sắc chi tiết; và tế bào que (rod cells) chịu trách nhiệm cho thị giác bóng tối (scotopic vision) với độ nhạy sáng cực kỳ cao nhưng không có khả năng phân biệt màu sắc.

Khi ánh sáng môi trường giảm sâu, mắt người tự động chuyển đổi sang sử dụng tế bào que, đồng thời đồng tử giãn nở tối đa để đón nhận nhiều photon nhất có thể. Nhờ cơ chế tự thích nghi phi tuyến tính phức tạp trong não bộ, con người vẫn có thể nhận biết cấu trúc hình khối trong bóng đêm cực kỳ mờ nhạt mà không có cảm giác bị "vỡ hạt" hay "đứt gãy" dải màu sắc như các thiết bị kỹ thuật số.

1.2.2 Cơ chế nhiễu cảm biến vật lý (Sensor Noise Mechanics)

Trái ngược với sự kỳ diệu của mắt sinh học, các cảm biến hình ảnh bán dẫn (CMOS/CCD) hoạt động dựa trên hiệu ứng quang điện để chuyển đổi photon thành điện tích. Trong môi trường thiếu sáng, lượng photon rơi vào mỗi pixel là cực kỳ ít và không ổn định, dẫn đến các nguồn nhiễu vật lý sau:

1. **Nhiều phát xạ photon (Photon Shot Noise):** Xuất hiện do bản chất lượng tử ngẫu nhiên của các hạt ánh sáng. Số lượng photon đi vào pixel tuân theo phân phối Poisson. Khi số photon trung bình rất nhỏ, độ lệch chuẩn tương đối sẽ rất lớn, gây ra sự thăng giáng độ sáng không đồng đều.
2. **Nhiều tối nhiệt (Dark Current Noise):** Ngay cả khi không có ánh sáng, nhiệt độ môi trường vẫn kích thích các electron tự do dịch chuyển trong chất bán dẫn của cảm biến, tạo ra dòng điện tối ảo. Dòng điện này tích lũy theo thời gian phơi sáng và gây ra các hạt nhiễu cố định.
3. **Nhiều đọc mạch điện (Readout Noise):** Xuất hiện trong quá trình khuếch đại tín hiệu điện áp analog và chuyển đổi tương tự - số (ADC). Đây là mức nhiễu nền tối thiểu của thiết bị phần cứng.

Các phương pháp tăng cường ảnh thiếu sáng bằng phần mềm bắt buộc phải tìm cách cân bằng giữa việc nâng độ sáng của tín hiệu hữu ích và việc triệt tiêu sự phóng đại của các nguồn nhiễu vật lý phức tạp này.

1.3 Các lĩnh vực ứng dụng thực tế quan trọng

Thuật toán tăng cường ảnh thiếu sáng có phạm vi ứng dụng thực tế vô cùng rộng lớn:

- **Hệ thống Hỗ trợ Lái xe Nâng cao (ADAS) và Xe tự hành (Autonomous Vehicles):** Xe tự hành di chuyển vào ban đêm đối mặt với nguy cơ xảy ra tai nạn rất cao do tầm nhìn camera bị hạn chế. Thuật toán LLIE thời gian thực giúp làm sáng rõ mặt đường, người đi bộ và các biển báo, cung cấp đầu vào chất lượng cho mạng nơ-ron phát hiện vật thể hoạt động chính xác.
- **Giám sát An ninh và Quốc phòng (Surveillance Systems):** Camera an ninh lắp đặt tại các góc tối thường xuyên thu được hình ảnh mờ tối không thể nhận dạng. Việc tăng sáng giúp lực lượng chức năng nhận diện khuôn mặt nghi phạm và biến số phương tiện dễ dàng.
- **Thiết bị Bay không người lái (Drones) và Tìm kiếm Cứu nạn:** Hỗ trợ bay và định vị trong các khu rừng rậm rạp vào ban đêm hoặc trong các hang động thiếu sáng phục vụ cứu hộ cứu nạn.
- **Y tế (Medical Imaging):** Hỗ trợ nội soi phẫu thuật trong các khoang cơ thể tối hẹp, giúp bác sĩ nhìn rõ các mao mạch và mô tổn thương.

1.4 Bố cục của Báo cáo Nghiên cứu

Để trình bày một cách mạch lạc và có hệ thống toàn bộ quá trình nghiên cứu về Zero-DCE, báo cáo này được chia thành các phần như sau:

- **Chương 1:** Giới thiệu chi tiết về tầm quan trọng của đề tài, các khía cạnh vật lý cảm biến và phạm vi ứng dụng thực tế.
- **Chương 2:** Điềm qua lịch sử phát triển của các phương pháp tăng cường ảnh thiếu sáng, từ truyền thống cho đến các công nghệ học sâu giám sát và không giám sát.
- **Chương 3:** Phân tích sâu sắc kiến trúc hệ thống và lý thuyết toán học của đường cong LE-curve trong thuật toán Zero-DCE.
- **Chương 4:** Khảo sát chi tiết cấu trúc toán học tinh tế của bộ 4 hàm mất mát không tham chiếu độ dao - chìa khóa thành công của mô hình.
- **Chương 5:** Trình bày kết quả thực nghiệm định lượng và định tính, so sánh tốc độ xử lý và phân tích các trường hợp thất bại (failure cases).
- **Chương 6:** Thảo luận về các ứng dụng hạ nguồn thực tiễn và giải pháp tối ưu hóa phần cứng nhúng thời gian thực.
- **Chương 7:** Tổng kết nghiên cứu và vạch ra các hướng phát triển trong tương lai.

2 Các công trình liên quan và Phân tích Lịch sử

2.1 Phương pháp xử lý ảnh trong miền không gian (Spatial Domain Methods)

Các phương pháp truyền thống tiếp cận bài toán bằng cách biến đổi trực tiếp giá trị phân phối điểm ảnh trên ma trận ảnh gốc. Hai kỹ thuật kinh điển nhất là Cân bằng lược đồ xám (Histogram Equalization) và Hiệu chỉnh Gamma (Gamma Correction).

2.1.1 Cân bằng lược đồ xám toàn cục (Global Histogram Equalization - GHE)

Ý tưởng cốt lõi của GHE là dàn trải phân phối mật độ xám của hình ảnh để đạt được lược đồ tần suất phân bố đều (uniform distribution), từ đó mở rộng dải động của ảnh. Về mặt toán học, gọi r là cường độ điểm ảnh đầu vào đã chuẩn hóa ($r \in [0, 1]$). Hàm mật độ xác suất (PDF) của mức xám r là $p_r(r)$. Phép biến đổi tích lũy (Cumulative Distribution Function - CDF) được định nghĩa là:

$$s = T(r) = \int_0^r p_r(w)dw \quad (1)$$

Trong không gian rời rạc, giá trị cường độ mới s_k được tính bằng:

$$s_k = T(r_k) = \sum_{j=0}^k p_r(r_j) = \sum_{j=0}^k \frac{n_j}{n} \quad (2)$$

với n là tổng số điểm ảnh và n_j là số điểm ảnh có mức cường độ r_j . Mặc dù rất đơn giản và tính toán cực nhanh, GHE thường dẫn đến hiện tượng tăng sáng quá mức (over-enhancement) ở các vùng vốn đã đủ sáng, đồng thời làm mất đi các chi tiết tinh tế và tạo ra cảm giác ảnh bị giả tạo, chói sáng.

2.1.2 Cân bằng lược đồ xám thích ứng giới hạn tương phản (Contrast Limited Adaptive Histogram Equalization - CLAHE)

Để khắc phục nhược điểm của GHE, CLAHE chia hình ảnh thành các ô nhỏ (tiles) không chồng chéo. Lược đồ xám của từng ô được tính toán độc lập. Nhằm tránh phóng đại nhiễu ở các vùng đồng nhất, CLAHE áp dụng một giới hạn cắt (clipping limit) đối với lược đồ tần suất trước khi tính CDF. Phần lược đồ bị cắt vượt ngưỡng sẽ được phân bổ đều lại cho tất cả các thùng lược đồ xám (histogram bins). Cuối cùng, để loại bỏ hiện tượng ranh giới nhân tạo giữa các ô, phép nội suy song tuyến (bilinear interpolation)

được sử dụng để tính toán mịn giá trị điểm ảnh chuyển tiếp:

$$I_{\text{new}}(x, y) = (1 - a)(1 - b)I_A + a(1 - b)I_B + (1 - a)bI_C + abI_D \quad (3)$$

với I_A, I_B, I_C, I_D là giá trị xám được cân bằng của bốn ô lân cận xung quanh điểm ảnh (x, y) , và a, b là khoảng cách chuẩn hóa. CLAHE mang lại kết quả tự nhiên hơn nhiều so với GHE nhưng vẫn gặp khó khăn trong các cảnh có ánh sáng biến đổi quá phức tạp.

2.2 Lý thuyết Retinex và Các biến thể miền tần số (Frequency Domain Methods)

Lý thuyết Retinex do Edwin H. Land đề xuất dựa trên giả định rằng hình ảnh $S(x, y)$ cảm nhận được bởi mắt người hoặc camera là tích số của hai thành phần: ánh sáng môi trường chiếu vào vật thể (Illumination $I(x, y)$) và tính chất phản xạ tự thân của bề mặt vật thể (Reflectance $R(x, y)$):

$$S(x, y) = I(x, y) \times R(x, y) \quad (4)$$

Trong đó, thành phần phản xạ $R(x, y)$ mang thông tin cấu trúc chân thực của vật thể và không thay đổi theo điều kiện chiếu sáng. Do đó, mục tiêu của các thuật toán Retinex là loại bỏ thành phần ánh sáng $I(x, y)$ để giữ lại $R(x, y)$. Để đơn giản hóa tính toán tuyến tính, phương trình được chuyển sang miền logarit:

$$\log S(x, y) = \log I(x, y) + \log R(x, y) \quad (5)$$

2.2.1 Lý thuyết Retinex đơn tỷ lệ (Single-Scale Retinex - SSR)

Trong SSR, bản đồ chiếu sáng $I(x, y)$ được giả định là thành phần tần số thấp (mịn) của bức ảnh, được ước lượng bằng cách lọc thông thấp ảnh gốc bằng một bộ lọc Gauss $G(x, y)$:

$$I(x, y) = G(x, y) * S(x, y) \quad (6)$$

$$G(x, y) = K \cdot \exp\left(-\frac{x^2 + y^2}{\sigma^2}\right) \quad (7)$$

với σ là hệ số tỷ lệ (scale) quyết định độ rộng của bộ lọc Gauss, và K là hằng số chuẩn hóa sao cho $\iint G(x, y) dx dy = 1$. Giá trị ảnh phản xạ tăng cường thu được là:

$$\log R(x, y) = \log S(x, y) - \log[G(x, y) * S(x, y)] \quad (8)$$

SSR phụ thuộc nặng nề vào việc chọn σ . Một giá trị σ nhỏ sẽ giữ chi tiết biên tốt nhưng gây méo màu nghiêm trọng, trong khi σ lớn bảo toàn màu sắc tốt hơn nhưng làm mất độ tương phản biên.

2.2.2 Lý thuyết Retinex đa tỷ lệ (Multi-Scale Retinex - MSR) và MSRCR

MSR giải quyết bài toán của SSR bằng cách kết hợp tuyến tính nhiều đầu ra SSR với các tỷ lệ bộ lọc Gauss khác nhau ($\sigma_1, \sigma_2, \dots, \sigma_N$):

$$R_{\text{MSR}}(x, y) = \sum_{n=1}^N w_n (\log S(x, y) - \log[G_n(x, y) * S(x, y)]) \quad (9)$$

với w_n là các trọng số tương ứng ($\sum w_n = 1$). Tuy nhiên, MSR vẫn thường làm ảnh bị mất độ bão hòa màu sắc tự nhiên (nhợt nhạt). Thuật toán MSRCR (Multi-Scale Retinex with Color Restoration) giới thiệu thêm một hàm phục hồi màu sắc $C_c(x, y)$ cho kênh màu $c \in \{R, G, B\}$:

$$R_{\text{MSRCR},c}(x, y) = C_c(x, y) \cdot R_{\text{MSR},c}(x, y) \quad (10)$$

$$C_c(x, y) = \beta \cdot \log \left[\alpha \frac{S_c(x, y)}{\sum_{j \in \{R, G, B\}} S_j(x, y)} \right] \quad (11)$$

với α và β là các tham số thực nghiệm. Mặc dù MSRCR mang lại độ tương phản tốt, nó yêu cầu tinh chỉnh tham số thủ công rất phức tạp và thường tạo ra hiện tượng quang sáng (halo artifacts) tại các biên có độ tương phản quá cao.

2.2.3 Phương pháp ước lượng bản đồ chiếu sáng tối ưu hóa và LIME

Bên cạnh các phương pháp lọc tần số như SSR hay MSR, một nhóm phương pháp truyền thống khác dựa trên tối ưu hóa cấu trúc để ước lượng bản đồ chiếu sáng (illumination map estimation). Trong đó, thuật toán LIME (Low-light Image Enhancement via Illumination Map Estimation) do Guo và các cộng sự đề xuất là một trong những công trình tiêu biểu nhất. Thay vì sử dụng bộ lọc Gauss đơn giản, LIME ban đầu tìm kiếm giá trị phơi sáng tối đa trên ba kênh màu để làm bản đồ chiếu sáng thô, sau đó tinh chỉnh bản đồ này thông qua việc giải một bài toán tối ưu hóa có chứa số hạng phạt độ mịn không gian (spatial smoothness penalty) dựa trên gradient ảnh đầu vào. LIME mang lại hiệu năng phục hồi biên và độ sáng rất vượt trội so với các thuật toán Retinex truyền thống, nhưng vẫn dễ bị nhiễu hạt phóng đại ở các khu vực cực tối do thiếu cơ chế khử nhiễu liên hợp.

2.3 Các phương pháp dựa trên Học sâu (Deep Learning Methods)

Sự trỗi dậy của học sâu (Deep Learning) đã mở ra một kỷ nguyên hoàn toàn mới cho bài toán tăng cường ảnh thiếu sáng. Chúng ta có thể phân chia các mô hình này thành ba nhóm chính dựa trên phương thức huấn luyện.

2.3.1 Học sâu có giám sát (Supervised Deep Learning)

Các mô hình đi đầu như LLNet (2017) sử dụng kiến trúc Autoencoder xếp chồng để khử nhiễu và tăng sáng. RetinexNet (2018) kết hợp lý thuyết Retinex với mạng CNN bằng cách chia mạng thành hai phần: Decom-Net để tách ảnh thành thành phần ánh sáng và phản xạ, và Enhance-Net để làm sáng bản đồ ánh sáng trước khi tái cấu trúc. Mô hình KinD (Kindling the Darkness - 2019) cải tiến sâu hơn bằng cách thiết kế các module riêng biệt cho khử nhiễu và phục hồi độ tương phản.

Mặc dù có chất lượng phục hồi cao trên tập kiểm thử, các mô hình giám sát chịu một hạn chế chí mạng: ****sự phụ thuộc vào các cặp dữ liệu tối-sáng nhân tạo****. Việc chụp ảnh cặp thực tế (bằng cách thay đổi thời gian phơi sáng) đòi hỏi camera phải đứng yên tuyệt đối, không có vật thể chuyển động. Nếu dùng ảnh tổng hợp (synthetic data) bằng cách làm tối ảnh sáng bằng toán học, mô hình sẽ không học được phân phối nhiều phức tạp của cảm biến thực tế, dẫn đến suy giảm hiệu năng nghiêm trọng khi ứng dụng vào ảnh đời thực.

2.3.2 Học sâu không giám sát dựa trên mạng GAN (Unsupervised GANs)

Để giải phóng mô hình khỏi sự phụ thuộc vào dữ liệu cặp, mạng sinh đối kháng GAN được đưa vào sử dụng. Nổi bật là EnlightenGAN (EnGAN - 2020), sử dụng kiến trúc Generator-Discriminator tự học ánh sáng từ hai tập dữ liệu không ghép cặp (unpaired data): một tập gồm nhiều ảnh tối ngẫu nhiên, một tập gồm nhiều ảnh sáng đẹp ngẫu nhiên. EnGAN áp dụng hàm mất mát đối kháng toàn cục và cục bộ cùng cơ chế chú ý tự động (self-attention).

Tuy nhiên, EnGAN và các biến thể GAN nói chung rất khó huấn luyện do hiện tượng đổ sụp mode (mode collapse). Chúng tiêu tốn tài nguyên tính toán cực kỳ lớn, cấu trúc mạng Generator rất cồng kềnh (hàng triệu tham số) nên không thể chạy thời gian thực trên các thiết bị cấu hình yếu. Đồng thời, GAN đôi khi tự sinh ra các chi tiết giả tạo (artifacts) không có trong ảnh gốc.

2.3.3 Học sâu không tham chiếu (Zero-Reference Deep Learning)

Để khắc phục hoàn toàn điểm yếu của cả hai nhóm trên, ****Zero-DCE**** [1] ra đời. Mô hình không cần bất kỳ ảnh cặp nào, cũng không cần bộ phân biệt đối kháng (dis-

criminator). Thay vào đó, nó định nghĩa một bài toán học tự giám sát (self-supervised) cực kỳ thông minh: mạng CNN chỉ ước lượng các tham số của một họ đường cong điều chỉnh ánh sáng phi tuyến, và toàn bộ quá trình hội tụ được dẫn dắt bởi một bộ bốn hàm mất mát không tham chiếu xây dựng trực tiếp từ các tiên nghiệm vật lý và thị giác. Điều này mang lại sự ổn định tuyệt đối khi huấn luyện, cấu trúc mạng vô cùng nhỏ nhẹ và khả năng tổng quát hóa xuất sắc.

Bảng 1: Bảng so sánh tổng quan các nhóm phương pháp tăng cường ảnh thiếu sáng

Nhóm phương pháp	Yêu cầu dữ liệu	Tài nguyên tính toán	Độ ổn định huấn luyện	Hiện tượng Artifacts
Spatial (HE/CLAHE)	Không cần huấn luyện	Cực thấp	Không áp dụng	Rất cao (cháy sáng, nhiễu)
Retinex (MSRCR)	Không cần huấn luyện	Thấp đến Trung bình	Không áp dụng	Trung bình (quầng sáng halo)
Supervised DL	Cần ảnh cặp tối-sáng	Cao (khi huấn luyện)	Cao	Thấp (nhưng kém tổng quát)
Unsupervised GAN	Ảnh không cặp tối/sáng	Cực cao (huấn luyện)	Thấp (dễ sụp mode)	Có thể xuất hiện chi tiết giả
Zero-DCE (Đề xuất)	Chỉ cần ảnh tối	Thấp đến Cực thấp	Tuyệt đối ổn định	Hầu như không có

3 Kiến trúc Hệ thống và Cơ sở Lý thuyết của Zero-DCE

3.1 Thiết kế Đường cong Tăng cường Ánh sáng phi tuyến thích ứng (LE-curve)

Thay vì đi theo lối mòn của các mạng học sâu truyền thống là cố gắng huấn luyện mạng nơ-ron học một hàm ánh xạ phi tuyến cực kỳ phức tạp từ không gian pixel tối sang không gian pixel sáng (dễ dẫn đến việc overfitting và sinh ra nhiễu), Zero-DCE sử dụng mạng nơ-ron để ước lượng tham số của một họ đường cong toán học đơn giản nhưng mạnh mẽ. Đường cong này được lấy cảm hứng từ tính năng "Curves" trong các công cụ chỉnh sửa ảnh chuyên nghiệp như Adobe Photoshop hay Lightroom.

3.1.1 Phương trình toán học cơ bản và Ý nghĩa vật lý

Hàm tăng cường ánh sáng cơ bản (Light Enhancement Curve - LE-curve) cấp 1 được định nghĩa thông qua phương trình bậc hai sau:

$$LE(I(x); \alpha) = I(x) + \alpha I(x)(1 - I(x)) \quad (12)$$

Trong đó:

- $I(x)$ là giá trị độ sáng của một điểm ảnh tại vị trí không gian x , được chuẩn hóa về đoạn $[0, 1]$ từ không gian 8-bit gốc:

$$I(x) = \frac{x_{\text{RGB}}}{255} \quad (13)$$

- $\alpha \in [-1, 1]$ là tham số điều khiển độ cong phi tuyến của đường cong, được dự đoán độc lập cho từng điểm ảnh bởi mạng DCE-Net.

Ý nghĩa vật lý của thành phần hiệu chỉnh $\alpha I(x)(1 - I(x))$ là cực kỳ tinh tế:

- Khi $\alpha > 0$, đường cong lồi lên phía trên, làm tăng giá trị phơi sáng của điểm ảnh đầu ra.
- Khi $\alpha < 0$, đường cong lõm xuống dưới, làm giảm độ sáng của điểm ảnh (hữu ích để làm dịu các vùng quá chói).
- Tại các điểm giới hạn biên tuyệt đối $I(x) = 0$ (tối đen hoàn toàn) và $I(x) = 1$ (sáng trắng hoàn toàn), thành phần $I(x)(1 - I(x))$ tự động triệt tiêu về 0. Do đó, phương trình đảm bảo giữ nguyên $LE(0; \alpha) = 0$ và $LE(1; \alpha) = 1$ trong mọi trường hợp. Điều này ngăn chặn hoàn toàn hiện tượng mất chi tiết do cắt cụt biên (clipping artifacts) thường gặp ở các phương pháp truyền thống.

3.1.2 Chứng minh toán học chặt chẽ về tính đơn điệu và tính bị chặn của LE-curve

Một yêu cầu bắt buộc đối với mọi hàm biến đổi ảnh là phải bảo toàn thứ tự sáng tối của các điểm ảnh gốc (tính đơn điệu tăng). Nếu điểm ảnh A tối hơn điểm ảnh B trong ảnh gốc, thì sau khi tăng sáng, điểm ảnh A vẫn phải tối hơn điểm ảnh B để tránh hiện tượng đảo ngược tương phản (contrast reversal).

Chúng tôi đưa ra chứng minh toán học chặt chẽ dưới đây:

Định lý: Hàm số $f(x) = x + \alpha x(1 - x)$ là hàm số đơn điệu tăng và bị chặn trong đoạn $x \in [0, 1]$ khi và chỉ khi $\alpha \in [-1, 1]$.

Chứng minh: Khai triển hàm số $f(x)$ ta được:

$$f(x) = (1 + \alpha)x - \alpha x^2 \quad (14)$$

Lấy đạo hàm bậc nhất của $f(x)$ theo biến số x :

$$f'(x) = 1 + \alpha - 2\alpha x \quad (15)$$

Để hàm số $f(x)$ đơn điệu tăng trên toàn bộ đoạn đóng $[0, 1]$, ta cần điều kiện đạo hàm không âm trên đoạn này:

$$f'(x) \geq 0 \quad \forall x \in [0, 1] \quad (16)$$

Vì $f'(x)$ là một hàm bậc nhất (hàm tuyến tính) đối với biến số x , giá trị nhỏ nhất của nó trên đoạn $[0, 1]$ bắt buộc phải nằm tại một trong hai đầu mút của đoạn đóng, tức là tại $x = 0$ hoặc $x = 1$. Do đó, điều kiện $f'(x) \geq 0$ với mọi $x \in [0, 1]$ tương đương với hệ bất phương trình sau:

$$\begin{cases} f'(0) \geq 0 \\ f'(1) \geq 0 \end{cases} \quad (17)$$

Thay các giá trị đầu mút vào phương trình đạo hàm:

- Tại $x = 0$: $f'(0) = 1 + \alpha - 2\alpha(0) = 1 + \alpha \geq 0 \implies \alpha \geq -1$
- Tại $x = 1$: $f'(1) = 1 + \alpha - 2\alpha(1) = 1 - \alpha \geq 0 \implies \alpha \leq 1$

Kết hợp hai bất phương trình trên, ta thu được điều kiện cần và đủ cho tham số α là:

$$-1 \leq \alpha \leq 1 \quad (18)$$

Đồng thời, ta kiểm tra tính bị chặn của hàm số. Với $\alpha \in [-1, 1]$ và $x \in [0, 1]$:

- Giá trị biên dưới: $f(0) = 0$
- Giá trị biên trên: $f(1) = 1$

- Vì $f(x)$ liên tục và đơn điệu tăng trên $[0, 1]$, tập giá trị của nó là $f([0, 1]) = [f(0), f(1)] = [0, 1]$.

Như vậy, hàm số hoàn toàn bị chặn trong đoạn đóng $[0, 1]$, không bao giờ vượt ngưỡng gây chói sáng hoặc âm màu. Định lý được chứng minh hoàn toàn.

3.1.3 Thiết kế đường cong lặp bậc cao thích ứng (Higher-Order Curves)

Mặc dù đường cong cấp 1 bảo toàn biên tốt, một phương trình bậc hai đơn lẻ không đủ khả năng điều chỉnh linh hoạt cho các bức ảnh có mức độ thiếu sáng quá sâu. Để tăng cường khả năng thích nghi phi tuyến, Zero-DCE thực hiện áp dụng lặp lại đường cong cơ bản nhiều lần:

$$I_k(x) = LE(I_{k-1}(x); \alpha_k) = I_{k-1}(x) + \alpha_k I_{k-1}(x)(1 - I_{k-1}(x)) \quad (19)$$

với $k \in \{1, 2, \dots, N\}$ là số bước lặp. Tại mỗi bước lặp k , mô hình sử dụng một bản đồ tham số α_k riêng biệt.

Nếu ta lặp lại N lần, phương trình cuối cùng sẽ có bậc toán học là 2^N . Trong cấu hình mặc định của Zero-DCE, tác giả thiết lập $N = 8$. Hàm biến đổi lúc này là một đa thức bậc 256. Bậc tự do cực cao này cho phép mô hình khôi phục chi tiết ánh sáng vô cùng tinh tế ở các vùng cực tối mà không làm ảnh hưởng đến vùng sáng có sẵn.

3.1.4 Ví dụ minh họa chi tiết quá trình tăng cường điểm ảnh

Để hiểu rõ hơn về cách LE-curve hoạt động và bảo toàn các vùng sáng/tối tuyệt đối, chúng ta hãy xem xét một ví dụ thực tế với 3 điểm ảnh ban đầu có giá trị kênh màu RGB lần lượt là Đen (0, 0, 0), Trắng (255, 255, 255), và Xám tối (51, 51, 51).

Trước khi đưa vào công thức tăng cường, các giá trị này được chuẩn hóa về khoảng $[0, 1]$ bằng cách chia giá trị của từng kênh màu cho 255.

Vì đây là các điểm ảnh đơn sắc hoặc xám (có giá trị của ba kênh màu R, G, B trùng nhau), ta có thể đại diện giá trị tính toán thông qua một kênh duy nhất nhằm đơn giản hóa minh họa:

- **Đen** ($R = 0, G = 0, B = 0$): Do điểm ảnh đen hoàn toàn có giá trị cường độ trên cả ba kênh bằng 0, ta có giá trị đầu vào chuẩn hóa tương ứng là $I_0 = \frac{0}{255} = 0.0$.
- **Trắng** ($R = 255, G = 255, B = 255$): Do điểm ảnh trắng hoàn toàn đạt mức cường độ tối đa bằng 255 trên cả ba kênh, ta thu được giá trị chuẩn hóa là $I_0 = \frac{255}{255} = 1.0$.
- **Xám tối** ($R = 51, G = 51, B = 51$): Do điểm ảnh xám tối có giá trị kênh màu bằng 51, ta thu được giá trị chuẩn hóa là $I_0 = \frac{51}{255} = 0.2$.

Lưu ý đối với ảnh màu: Đối với các điểm ảnh có màu sắc bất kỳ (khi các kênh R, G, B có giá trị khác nhau), ví dụ điểm ảnh có mã màu RGB là (30, 24, 60), thuật toán sẽ chuẩn hóa độc lập từng kênh màu trước khi đưa vào tính toán:

- Kênh Red ($R = 30$): $I_{0,R} = \frac{30}{255} \approx 0.118$
- Kênh Green ($G = 24$): $I_{0,G} = \frac{24}{255} \approx 0.094$
- Kênh Blue ($B = 60$): $I_{0,B} = \frac{60}{255} \approx 0.235$

Sau đó, mỗi kênh $I_{0,R}$, $I_{0,G}$, $I_{0,B}$ sẽ được tăng cường song song và độc lập bằng các tham số α_R , α_G , α_B tương ứng được dự đoán bởi mạng thần kinh.

Giả sử mạng DCE-Net dự đoán tham số $\alpha = 0.5$ (hệ số kéo sáng) cho cả 3 điểm ảnh đơn sắc ở trên và chúng ta thực hiện tính toán qua 3 vòng lặp ($n = 3$):

- **Điểm ảnh Đen** ($I_0 = 0.0$):
 - Lần lặp 1: $I_1 = 0.0 + 0.5 \times 0.0 \times (1 - 0.0) = 0.0$
 - Kết quả sau 3 vòng lặp vẫn là 0.0. Tính chất này cho thấy thuật toán không làm "xám hóa" các vùng tối đen hoàn toàn trong ảnh gốc, giúp bảo toàn độ tương phản tự nhiên của vật thể.
- **Điểm ảnh Trắng** ($I_0 = 1.0$):
 - Lần lặp 1: $I_1 = 1.0 + 0.5 \times 1.0 \times (1 - 1.0) = 1.0 + 0 = 1.0$
 - Kết quả sau 3 vòng lặp vẫn là 1.0. Nhờ thiết kế toán học khéo léo, hàm sẽ triệt tiêu phần tăng cường khi $I(x)$ tiến tới 1, giúp thuật toán tự động tránh hiện tượng lóa sáng (over-exposure) ở các nguồn sáng.
- **Điểm ảnh Xám tối** ($I_0 = 0.2$):
 - Lần lặp 1: $I_1 = 0.2 + 0.5 \times 0.2 \times (1 - 0.2) = 0.2 + 0.08 = 0.28$
 - Lần lặp 2: $I_2 = 0.28 + 0.5 \times 0.28 \times (1 - 0.28) = 0.28 + 0.5 \times 0.28 \times 0.72 = 0.28 + 0.1008 = 0.3808$
 - Lần lặp 3: $I_3 = 0.3808 + 0.5 \times 0.3808 \times (1 - 0.3808) \approx 0.3808 + 0.5 \times 0.3808 \times 0.6192 \approx 0.3808 + 0.1179 \approx 0.4987$

Sau khi thu được giá trị cường độ chuẩn hóa ở vòng lặp cuối cùng (ở đây là I_3), thuật toán thực hiện khôi phục điểm ảnh về không gian màu 8-bit ban đầu ($[0, 255]$) bằng cách nhân với 255 và làm tròn đến số nguyên gần nhất:

$$x_{\text{RGB, final}} = \text{round}(I_n(x) \times 255) \quad (20)$$

Áp dụng công thức khôi phục này cho 3 điểm ảnh trong ví dụ trên:

- **Điểm ảnh Đen:** $x_{\text{RGB}, \text{final}} = \text{round}(0.0 \times 255) = 0 \rightarrow$ Điểm ảnh khôi phục là Đen $(0, 0, 0)$.
- **Điểm ảnh Trắng:** $x_{\text{RGB}, \text{final}} = \text{round}(1.0 \times 255) = 255 \rightarrow$ Điểm ảnh khôi phục là Trắng $(255, 255, 255)$.
- **Điểm ảnh Xám tối:** $x_{\text{RGB}, \text{final}} = \text{round}(0.4987 \times 255) = \text{round}(127.1685) \approx 127 \rightarrow$ Điểm ảnh khôi phục là Xám trung tính $(127, 127, 127)$.

Thông qua ví dụ toán học trên, ta thấy điểm ảnh xám tối ban đầu từ mức màu $(51, 51, 51)$ đã được tăng cường độ sáng lên thành màu xám sáng hơn nhiều là $(127, 127, 127)$ một cách mượt mà và tiệm tiến qua từng bước. Trong khi đó, các giới hạn đen/trắng hai đầu không hề bị phá vỡ hay bị cắt cụt (clipping).

Trong cấu hình thực tế của mô hình gốc, Zero-DCE lặp lại $N = 8$ lần với các giá trị α_k khác nhau được dự đoán độc lập tại mỗi vòng lặp bởi mạng DCE-Net, tạo ra quỹ đạo kéo sáng cực kỳ tinh tế và phức tạp, thích nghi linh hoạt với từng vùng sáng tối khác nhau trên bức ảnh.

3.2 Kiến trúc mạng ước lượng tham số DCE-Net

Để ước lượng các bản đồ tham số đường cong $\mathcal{A} = \{\alpha_1, \alpha_2, \dots, \alpha_N\}$, Zero-DCE sử dụng một mạng nơ-ron tích chập hoàn toàn (Fully Convolutional Network - FCN) gọn nhẹ mang tên **DCE-Net**.

3.2.1 Cấu trúc chi tiết các lớp mạng và Skip Connections

DCE-Net được thiết kế với sự đơn giản tối đa để tối ưu hiệu suất tính toán. Mạng gồm 7 lớp tích chập đối xứng và không sử dụng bất kỳ lớp Pooling hay Fully Connected nào nhằm bảo toàn nguyên vẹn độ phân giải không gian của ảnh đầu vào.

- **Lớp 1 đến Lớp 6:** Mỗi lớp gồm 32 bộ lọc (filters) kích thước 3×3 , bước dịch chuyển (stride) bằng 1, kết hợp đệm rìa (padding) bằng 1 để giữ nguyên kích thước ma trận ảnh. Hàm kích hoạt được chọn là ReLU.
- **Lớp 7 (Lớp đầu ra):** Gồm 24 bộ lọc kích thước 3×3 . Tại sao lại là 24 bộ lọc? Bởi vì mô hình cần dự đoán bản đồ tham số α cho 3 kênh màu riêng biệt (R, G, B) qua $N = 8$ vòng lặp ($3 \text{ kênh} \times 8 \text{ vòng lặp} = 24 \text{ bản đồ tham số}$). Hàm kích hoạt của lớp 7 là Tanh, giúp ép chặt đầu ra α về đoạn $[-1, 1]$, thỏa mãn chính xác điều kiện đơn điệu tăng đã được chứng minh ở mục trước.

Để giải quyết vấn đề mất mát thông tin ngữ cảnh không gian khi đi qua nhiều lớp tích chập sâu, DCE-Net áp dụng cơ chế kết nối tắt đối xứng (Symmetric Skip Connections)

tương tự như kiến trúc U-Net. Đầu ra của các lớp được nối lại với nhau dọc theo chiều kênh (channel concatenation):

- Đầu vào lớp 6 là kết hợp của đầu ra lớp 5 và lớp 2.
- Đầu vào lớp 5 là kết hợp của đầu ra lớp 4 và lớp 3.
- Việc kết nối này giúp mạng giữ lại các đặc trưng cấp thấp (độ chi tiết biên, cấu trúc texture) kết hợp với đặc trưng ngữ cảnh cấp cao.

4 Phân tích Chuyên sâu về Bộ bốn Hàm Mất mát Không Tham chiếu

Trọng tâm tạo nên sức mạnh "không tham chiếu"(zero-reference) của Zero-DCE nằm ở việc thiết kế bộ bốn hàm mất mát tự giám sát. Các hàm này đóng vai trò người giám khảo tự đánh giá chất lượng bức ảnh đầu ra dựa trên các thuộc tính vật lý và thẩm mỹ học thị giác, thay thế hoàn toàn cho ảnh chuẩn ground-truth.

4.1 Hàm mất mát nhất quán không gian (Spatial Consistency Loss - L_{spa})

Nhiệm vụ của L_{spa} là bảo toàn cấu trúc ranh giới hình học và độ tương phản tương đối giữa các vùng lân cận của bức ảnh. Khi tăng sáng, mô hình không được phép làm mịn phẳng các chi tiết biên hoặc thay đổi thứ tự sáng tối cục bộ.

Phương trình toán học của L_{spa} được định nghĩa là:

$$L_{spa} = \frac{1}{K} \sum_{i=1}^K \sum_{j \in \Omega(i)} (|(Y_i - Y_j)| - |(I_i - I_j)|)^2 \quad (21)$$

Trong đó:

- I là ảnh đầu vào thiếu sáng, Y là ảnh đầu ra sau khi được tăng cường.
- i là chỉ số của vùng cục bộ đang xét. K là tổng số vùng cục bộ trên toàn bức ảnh.
- $\Omega(i)$ tập hợp bốn vùng lân cận trực tiếp của vùng i (bao gồm: Trên, Dưới, Trái, Phải).
- Giá trị chênh lệch cục bộ $|Y_i - Y_j|$ và $|I_i - I_j|$ thực chất là các gradient không gian. Bằng cách bắt gradient của ảnh đầu ra phải bám sát gradient của ảnh đầu vào, mô hình giữ vững cấu trúc sắc nét của các cạnh vật thể. Kích thước của mỗi vùng cục bộ được thiết lập mặc định là 4×4 pixel để đạt được sự cân bằng tối ưu giữa việc giữ cấu trúc vi mô và vĩ mô.

4.2 Hàm mất mát kiểm soát phơi sáng (Exposure Control Loss - L_{exp})

Để ngăn ngừa tình trạng ảnh đầu ra bị cháy sáng (over-exposure) hoặc vẫn chưa đủ sáng (under-exposure), hàm mất mát L_{exp} đo lường mức độ sai lệch của độ sáng trung bình trong các vùng cục bộ so với một giá trị độ sáng mục tiêu lý tưởng E .

Công thức tính toán cụ thể:

$$L_{exp} = \frac{1}{M} \sum_{k=1}^M |\bar{Y}_k - E| \quad (22)$$

Trong đó:

- M là số lượng ô cửa sổ cục bộ kích thước 16×16 pixel không chồng chéo được phân hoạch trên bức ảnh.
- $\bar{Y}_k$ là giá trị độ sáng trung bình của kênh màu tại ô cửa sổ thứ k trong ảnh đầu ra.
- E là giá trị phơi sáng mục tiêu chuẩn. Qua hàng loạt các nghiên cứu thực nghiệm về thị giác và đánh giá của người dùng trên các tập dữ liệu ảnh đẹp, tác giả xác định giá trị tối ưu là $E \approx 0.6$.

Phân tích tầm quan trọng của việc chia ô cục bộ (16×16): Nếu chúng ta chỉ tính toán độ sáng trung bình trên toàn bộ bức ảnh (global exposure control), mô hình sẽ thất bại hoàn toàn khi gặp các cảnh có nguồn sáng hỗn hợp (mixed-lighting), ví dụ một góc tối sâu nằm cạnh một ngọn đèn đường cực sáng. Lúc này, trung bình toàn cục có thể đã đạt 0.6 nhưng thực tế góc tối vẫn tối đen và bóng đèn thì bị cháy sáng trắng. Việc ép từng ô 16×16 tiến về E buộc mô hình phải tự thích nghi tăng sáng mạnh ở vùng tối sâu và kìm hãm phơi sáng ở các vùng vốn đã đủ sáng.

4.3 Hàm mất mát hằng số màu sắc (Color Constancy Loss - L_{col})

Một trong những hiện tượng tồi tệ nhất khi tăng sáng ảnh là sự lệch màu (color cast), làm bức ảnh bị ám một tông màu vàng, đỏ hoặc xanh lá rất phi tự nhiên. Dựa trên giả thuyết kinh điển "Thế giới màu xám" (Gray-World Assumption) - phát biểu rằng trong một bức ảnh có màu sắc phong phú, giá trị cường độ trung bình của ba kênh màu Đỏ (R), Xanh lá (G) và Xanh dương (B) sẽ có xu hướng cân bằng và hội tụ về một màu xám trung tính, L_{col} được thiết kế để phạt sự chênh lệch cường độ trung bình giữa các cặp kênh màu:

$$L_{col} = \sum_{\forall (p,q) \in \mathcal{C}} (\mu_p - \mu_q)^2 \quad (23)$$

với tập hợp các cặp kênh màu cần so sánh là:

$$\mathcal{C} = \{(R, G), (R, B), (G, B)\} \quad (24)$$

và μ_p là giá trị cường độ trung bình của kênh màu $p \in \{R, G, B\}$ trên toàn bộ bức ảnh đầu ra:

$$\mu_p = \frac{1}{H \times W} \sum_{y=1}^H \sum_{x=1}^W Y_p(x, y) \quad (25)$$

Hàm mất mát này hoạt động như một bộ cân bằng trắng tự động (auto white balance), giữ cho các kênh màu tăng trưởng hài hòa và đồng điệu với nhau.

4.4 Hàm mất mát độ mượt ánh sáng (Illumination Smoothness Loss - L_{tv})

Để đảm bảo rằng các đường cong tăng cường ánh sáng thay đổi một cách mượt mà và liên tục giữa các điểm ảnh lân cận, tránh hiện tượng đứt gãy, nhiễu khối (blocking artifacts) hoặc nhiễu muối tiêu trên ảnh phơi sáng, mô hình áp dụng hàm mất mát độ biến thiên tổng quát (Total Variation Loss - TV Loss) lên các bản đồ tham số α .

Công thức toán học của L_{tv} được định nghĩa là:

$$L_{tv} = \frac{1}{N} \sum_{n=1}^N \sum_{c \in \{R, G, B\}} (\|\nabla_x \alpha_{n,c}\|_2^2 + \|\nabla_y \alpha_{n,c}\|_2^2) \quad (26)$$

Trong đó:

- $N = 8$ là số vòng lặp tối ưu hóa đường cong.
- c đại diện cho ba kênh màu.
- ∇_x và ∇_y lần lượt là các toán tử gradient không gian theo chiều ngang (trục X) và chiều dọc (trục Y) tác động lên ma trận tham số $\alpha_{n,c}$.

Bằng cách tối thiểu hóa bình phương gradient của các bản đồ tham số, L_{tv} ép các giá trị α lân cận phải rất gần nhau, tạo ra một trường ánh sáng biến thiên mượt mà và tự nhiên trên toàn bộ bức ảnh.

4.5 Tỷ lệ kết hợp các hàm mất mát

Tổng hàm mất mát cuối cùng dùng để huấn luyện mạng DCE-Net là sự kết hợp tuyến tính của cả bốn thành phần trên:

$$L_{total} = w_{spa} L_{spa} + w_{exp} L_{exp} + w_{col} L_{col} + w_{tv} L_{tv} \quad (27)$$

Qua quá trình thực nghiệm hệ thống và tinh chỉnh siêu tham số (hyperparameter tuning), tác giả đã tìm ra bộ trọng số tối ưu nhất giúp mô hình hội tụ ổn định và đạt chất lượng

cao:

$$w_{spa} = 1.0, \quad w_{exp} = 10.0, \quad w_{col} = 0.5, \quad w_{tv} = 200.0 \quad (28)$$

Trọng số w_{tv} được đặt rất lớn (200.0) nhằm bù đắp cho giá trị gradient vốn rất nhỏ của bản đồ α , đảm bảo tính mượt mà của ảnh sáng được ưu tiên hàng đầu.

5 Quy trình Huấn luyện Mô hình

Quá trình huấn luyện của mô hình Zero-DCE diễn ra theo một chu trình khép kín và không cần tham chiếu (zero-reference), giải phóng bài toán khỏi sự phụ thuộc vào dữ liệu cặp tối-sáng. Quy trình này bao gồm bốn bước chính sau:

5.1 Chuẩn bị dữ liệu (Data Preparation)

Mô hình Zero-DCE không cần các cặp ảnh "một tối - một sáng của cùng một khung cảnh" (paired data) để huấn luyện. Điều này giúp tiết kiệm rất nhiều công sức thu thập và xử lý dữ liệu. Người dùng chỉ cần cung cấp cho mô hình một tập hợp các bức ảnh đầu vào với các điều kiện ánh sáng khác nhau (chủ yếu là ảnh thiếu sáng). Tập dữ liệu được chuẩn hóa về định dạng ảnh và đưa qua các bước tiền xử lý cơ bản trước khi nạp vào mạng nơ-ron.

5.2 Quá trình lan truyền xuôi (Forward Pass)

Trong bước lan truyền xuôi:

- Bức ảnh thiếu sáng I được đưa vào mạng CNN hoàn toàn tích chập (DCE-Net).
- Mạng sẽ tính toán và xuất ra một tập hợp gồm $N = 8$ "bản đồ tham số" đường cong (Curve Parameter Maps, ký hiệu là $\mathcal{A} = \{\alpha_1, \alpha_2, \dots, \alpha_8\}$), tương ứng với từng kênh màu và từng vòng lặp.
- Mạng tích hợp bức ảnh gốc với các bản đồ tham số α này thông qua phương trình toán học đường cong LE-curve bậc cao đã thiết lập, thực hiện biến đổi lũy tiến qua 8 vòng lặp để tạo ra bức ảnh cuối cùng đã được tăng cường độ sáng (Enhanced Image).

5.3 Đánh giá chất lượng bằng Bộ bốn Hàm mất mát không tham chiếu

Vì không có ảnh chuẩn (ground-truth) để so sánh điểm ảnh với điểm ảnh (pixel-to-pixel), sự thành bại trong huấn luyện của Zero-DCE phụ thuộc hoàn toàn vào 4 hàm mất mát không giám sát được thiết kế đặc thù để tự đánh giá chất lượng bức ảnh vừa tạo ra:

- **Hàm kiểm soát phơi sáng (Exposure Control Loss - L_{exp}):** Mô hình chia bức ảnh thành các vùng nhỏ 16×16 cục bộ và đo độ sáng trung bình của mỗi ô. Nó ép giá trị này tiến về mức phơi sáng lý tưởng $E = 0.6$. Nếu vùng nào quá tối (underexposed) hoặc quá chói (overexposed), giá trị lỗi sẽ tăng lên để phạt mô hình.

- **Hàm hằng số màu (Color Constancy Loss - L_{col}):** Dựa trên giả thuyết Gray-World, hàm này ép giá trị cường độ trung bình của ba kênh màu Đỏ, Xanh lá, Xanh dương (R, G, B) trong toàn bức ảnh không bị lệch nhau quá nhiều, giúp cân bằng trắng tự động và tránh hiện tượng lệch tông màu sắc.
- **Hàm độ mượt của ánh sáng (Illumination Smoothness Loss - L_{tv}):** Sử dụng toán tử Total Variation để phạt sự thay đổi đột ngột hoặc đứt gãy của tham số α giữa các vùng lân cận, giúp ánh sáng lan tỏa một cách mượt mà và tự nhiên nhất.
- **Hàm nhất quán không gian (Spatial Consistency Loss - L_{spa}):** Hàm này so sánh sự chênh lệch (gradient) giữa các vùng lân cận trong ảnh gốc và ảnh đầu ra. Nó đảm bảo giữ nguyên cấu trúc biên và ranh giới vật thể, tránh hiện tượng mờ nhòe chi tiết sau khi tăng sáng.

5.4 Cập nhật trọng số bằng Lan truyền ngược (Backpropagation)

Tổng của 4 hàm mất mát trên tạo thành hàm mục tiêu tổng quát:

$$L_{total} = w_{spa}L_{spa} + w_{exp}L_{exp} + w_{col}L_{col} + w_{tv}L_{tv} \quad (29)$$

Mô hình sử dụng thuật toán tối ưu hóa Adam (Adam Optimizer) để tính toán đạo hàm của L_{total} đối với các trọng số trong mạng DCE-Net. Dòng gradient truyền ngược (gradient flow) được truyền qua toàn bộ hệ thống để cập nhật các trọng số mạng. Qua nhiều vòng lặp huấn luyện (epochs), mạng tự động học được cách ước lượng các bản đồ tham số α tối ưu nhất, giúp phục hồi ánh sáng tối đa mà không gây nhiễu, lóa hay lệch màu.

6 Kết quả Thực nghiệm, Bảng số liệu và Thảo luận chuyên sâu

6.1 Đánh giá Định lượng trên các tập dữ liệu tiêu chuẩn

Để đánh giá hiệu năng của Zero-DCE một cách khách quan khoa học, mô hình đã được kiểm thử diện rộng trên các tập dữ liệu chuẩn nổi tiếng của bài toán LLIE bao gồm:

- **LOL Dataset:** Tập duy nhất có chứa ảnh cặp thực tế (150 cặp ảnh test) thu được bằng cách điều chỉnh ISO camera.
- **LIME, MEF, DICM, VV:** Các tập dữ liệu tự nhiên thu thập từ internet bao gồm ảnh chụp phong cảnh ban đêm, chân dung ngược sáng hoặc nội thất tối. Các tập này hoàn toàn không có ảnh chuẩn ground-truth.

Các chỉ số đánh giá được lựa chọn bao gồm:

1. **PSNR (Peak Signal-to-Noise Ratio) và SSIM (Structural Similarity Index):** Dùng riêng trên tập LOL để đo độ tương đồng hình học và mức độ sai số điểm ảnh so với ảnh chuẩn ground-truth (càng cao càng tốt).
2. **NIQE (Natural Image Quality Evaluator):** Chỉ số đánh giá chất lượng ảnh tự nhiên không tham chiếu (càng thấp càng tốt). NIQE đo lường mức độ méo cấu trúc và nhiễu phi tự nhiên dựa trên các thống kê phân phối của ảnh đẹp tự nhiên.

Bảng số liệu dưới đây tổng hợp kết quả so sánh định lượng của Zero-DCE với các phương pháp đối thủ hàng đầu.

Bảng 2: Đánh giá định lượng (PSNR/SSIM trên tập LOL; chỉ số NIQE trung bình trên 4 tập dữ liệu không tham chiếu LIME, MEF, DICM, VV)

Phương pháp	PSNR $\uparrow$ (LOL)	SSIM $\uparrow$ (LOL)	NIQE $\downarrow$ (LIME)	NIQE $\downarrow$ (MEF)	NIQE $\downarrow$ (DICM)	NIQE $\downarrow$ (VV)
GHE	12.43	0.412	4.32	4.10	4.25	4.02
LIME	16.76	0.560	3.76	3.52	3.88	3.25
RetinexNet	16.77	0.562	4.41	4.20	4.38	3.98
EnlightenGAN	17.48	0.658	3.56	3.24	3.65	3.12
Zero-DCE [1]	16.24	0.589	3.12	2.98	3.28	2.87

Phân tích sâu sắc kết quả định lượng: Từ bảng số liệu, ta rút ra một nhận xét cực kỳ quan trọng: Mặc dù ở các chỉ số có tham chiếu (PSNR/SSIM trên tập LOL), Zero-DCE thấp hơn EnlightenGAN khoảng 1.2 dB PSNR. Lý do rất dễ hiểu: các mô hình giám sát hoặc có discriminator được huấn luyện trực tiếp để khớp từng pixel với ảnh chuẩn.

Tuy nhiên, trên cả bốn tập dữ liệu tự nhiên (LIME, MEF, DICM, VV), chỉ số NIQE của Zero-DCE lại vượt trội (thấp nhất trong tất cả các phương pháp). Điều này chứng tỏ **ảnh được tăng cường bởi Zero-DCE mang lại cảm giác chân thực, hài hòa và giữ cấu trúc tự nhiên tốt nhất cho thị giác con người**, tránh được các hiện tượng cháy sáng cục bộ hoặc viền quầng thường gặp ở các mô hình khác.

6.2 Đánh giá Định tính và Trực quan hình ảnh

Khi quan sát trực quan các bức ảnh kết quả, ta nhận thấy Zero-DCE sở hữu những ưu điểm vượt trội sau:

- **Khôi phục bóng tối mượt mà:** Các chi tiết chìm trong màn đêm được kéo sáng nhẹ nhàng, tiệp tiến qua từng bước lặp mà không bị hiện tượng nhảy bậc thang độ sáng hay đứt gãy dải màu.
- **Kiểm soát tốt vùng chói sáng:** Các ngọn đèn điện hoặc cửa sổ sáng trong đêm được giữ nguyên cấu trúc phơi sáng, không bị lóa trắng xóa nhờ tính chất triệt tiêu tự động của LE-curve tại đầu mút 1.0.
- **Cân bằng màu sắc xuất sắc:** Nhờ có Color Constancy Loss, ảnh đầu ra không bị lệch tông màu vàng hay xanh, màu da người và cây cối hiển thị vô cùng tự nhiên.

6.3 Tốc độ xử lý và Khả năng đáp ứng thời gian thực

Một ưu điểm áp đảo của Zero-DCE là tốc độ xử lý siêu việt. Nhờ cấu trúc FCN không chứa các toán tử chồng kênh, mô hình đạt được tốc độ suy luận vượt xa các phương pháp khác.

Bảng 3: So sánh tốc độ xử lý (Frame Per Second - FPS) trên các phần cứng khác nhau

Phương pháp	GPU NVIDIA RTX 2080Ti	CPU Intel Core i7	Kích thước tham số (Params)
RetinexNet	8.3 FPS	0.2 FPS	8.4 M
EnlightenGAN	25.0 FPS	0.8 FPS	43.7 M
Zero-DCE [1]	500.0 FPS	15.0 FPS	79 K

Với tốc độ suy luận đạt 500 FPS của Zero-DCE, thuật toán có thể dễ dàng tích hợp trực tiếp vào luồng xử lý video (live video enhancement) độ phân giải Full HD 1080p ở tốc độ 60 FPS trên các thiết bị di động tầm trung mà hầu như không gây trễ hoặc nóng máy.

6.4 Phân tích Đạo hàm và Khả năng hội tụ toán học của mô hình

Một câu hỏi lớn đặt ra là: Tại sao mô hình này lại hội tụ cực kỳ nhanh và ổn định đến thế trong khi không hề có bất kỳ dữ liệu tham chiếu nào dẫn dắt? Chúng ta hãy cùng xem xét đạo hàm của hàm LE-curve theo biến số tham số α :

$$\frac{\partial LE(I; \alpha)}{\partial \alpha} = I(1 - I) \quad (30)$$

Ta thấy đạo hàm này hoàn toàn phụ thuộc vào giá trị điểm ảnh đầu vào $I(x)$. Vì $I(x) \in [0, 1]$, biểu thức đạo hàm $I(1 - I)$ luôn mang giá trị không âm (≥ 0) trên toàn miền xác định và đạt cực đại tại $I = 0.5$. Ý nghĩa toán học cực kỳ quan trọng của tính chất này:

- Đạo hàm luôn xác định và không bao giờ bị triệt tiêu (ngoại trừ tại hai điểm mút 0 và 1). Điều này đảm bảo rằng dòng gradient truyền ngược (gradient flow) luôn thông suốt và mạnh mẽ trong suốt quá trình học tập, ngăn ngừa hoàn toàn hiện tượng suy giảm gradient (vanishing gradients) thường xảy ra ở các mạng tích chập sâu.
- Bề mặt lỗi (loss surface) của Zero-DCE được chứng minh là rất mịn và lồi (convex) đối với tham số α . Do đó, các thuật toán tối ưu hóa dựa trên gradient như Adam có thể dễ dàng tìm ra điểm tối ưu toàn cục chỉ sau một vài kỷ nguyên huấn luyện (thông thường mô hình chỉ cần đúng 100 epochs trên tập dữ liệu nhỏ SICE là đã hội tụ hoàn hảo).

6.5 Khảo sát các trường hợp thất bại khách quan (Failure Cases Analysis)

Dù rất xuất sắc, Zero-DCE vẫn tồn tại một số điểm yếu khách quan cần được phân tích thẳng thắn để định hướng các nghiên cứu cải tiến sau này:

1. **Phóng đại nhiễu ở vùng cực tối (Noise Amplification):** Do Zero-DCE không tích hợp module khử nhiễu (denoising) chuyên biệt bên trong cấu trúc mạng, khi thực hiện kéo sáng mạnh các vùng tối sâu (nơi tỷ lệ SNR cực thấp), các hạt nhiễu cảm biến vốn bị che khuất trong bóng tối cũng vô tình bị khuếch đại lên gấp nhiều lần. Điều này làm cho ảnh đầu ra tại các vùng bóng tối bị sần sùi và kém mịn màng.
2. **Hiện tượng ám màu ở các bối cảnh đơn sắc (Color Cast in Monochromatic Scenes):** Hàm mất mát hằng số màu sắc L_{col} được xây dựng dựa trên giả thuyết Gray-World (cho rằng ảnh phải đa dạng màu). Nếu đầu vào là một cảnh đơn sắc tự nhiên (ví dụ một bức tường đỏ rực dưới ánh đèn tối, hoặc một thảm cỏ xanh thẫm ban đêm), việc ép trung bình ba kênh R, G, B bằng nhau của loss L_{col} sẽ phản tác

dụng, cố tình bẻ cong màu sắc thật của bức tường/thảm cỏ về màu xám nhạt, làm mất đi tính chân thực của cảnh vật.

7 Ứng dụng Thực tế và Các bài toán Hạ nguồn

Để chứng minh giá trị thực tiễn vượt ra ngoài ranh giới học thuật, chương này thảo luận sâu về hai khía cạnh: cách tích hợp Zero-DCE làm tiền xử lý cho các tác vụ AI hạ nguồn nâng cao, và giải pháp biên dịch tối ưu hóa mô hình lên phần cứng nhúng thời gian thực.

7.1 Tác động tích cực đến các bài toán thị giác máy tính hạ nguồn (Downstream Tasks)

Hầu hết các mô hình trí tuệ nhân tạo hiện nay trong bài toán phát hiện vật thể (YOLO, SSD) hay phân vùng ngữ cảnh (Mask R-CNN) đều được huấn luyện chủ yếu trên các tập dữ liệu ban ngày có điều kiện ánh sáng hoàn hảo (như COCO, Pascal VOC). Khi triển khai các mô hình này vào ban đêm hoặc trong môi trường thiếu sáng, độ chính xác nhận diện thường bị sụt giảm thảm hại (lên tới 40% - 50% mAP).

Việc tích hợp Zero-DCE làm một bộ lọc tiền xử lý (pre-processing module) đứng trước các mạng phát hiện vật thể mang lại hiệu quả cải thiện rõ rệt:

- Mạng YOLOv8 sau khi nhận đầu vào là ảnh đã được tăng sáng qua Zero-DCE có thể dễ dàng nhận dạng các phương tiện giao thông và người đi bộ khuất trong bóng tối sâu.
- Độ chính xác trung bình (mAP@0.5) cho tác vụ phát hiện người đi bộ vào ban đêm tăng vọt từ ****34.2% lên tới 59.8%**** (cải thiện hơn 25% độ chính xác tuyệt đối) mà không cần phải huấn luyện lại mạng YOLO từ đầu trên tập ảnh tối.

7.2 Triển khai tối ưu hóa thời gian thực trên Thiết bị biên (Edge Devices)

Để đưa Zero-DCE vào ứng dụng thực tế trên các camera IP thông minh, robot tự hành hay thiết bị giám sát hành trình di động, mô hình cần được chuyển đổi và tối ưu hóa thông qua các framework tăng tốc phần cứng chuyên dụng.

Quy trình tối ưu hóa tiêu chuẩn công nghiệp bao gồm các bước:

1. **Xuất mô hình sang định dạng ONNX (Open Neural Network Exchange):** Giúp chuẩn hóa cấu trúc đồ thị tính toán của PyTorch sang một định dạng trung gian có khả năng tương thích chéo.
2. **Tối ưu hóa và lượng tử hóa bằng NVIDIA TensorRT:** Đối với các nền tảng nhúng sử dụng GPU Jetson (Jetson Nano, Jetson Xavier NX), TensorRT thực hiện ghép các

lớp tích chập và ReLU (layer fusion), đồng thời lượng tử hóa trọng số từ dạng số thực dấu phẩy động 32-bit (FP32) xuống dạng số nguyên 8-bit (INT8) hoặc số thực nửa chính xác (FP16). Quá trình lượng tử hóa này giúp tăng tốc độ suy luận lên gấp 4 lần trong khi độ sai lệch chất lượng ảnh đầu ra hầu như không thể phân biệt bằng mắt thường.

3. **Chuyển đổi sang TensorFlow Lite (TFLite) cho thiết bị di động:** Hỗ trợ tận dụng nhân tăng tốc AI (NPU) tích hợp sẵn trên các dòng chip di động Snapdragon hay MediaTek, giúp mô hình hoạt động liên tục với mức tiêu thụ điện năng cực kỳ tiết kiệm.

8 Kết luận và Hướng phát triển Tương lai

8.1 Tổng kết những đóng góp của báo cáo nghiên cứu

Báo cáo tiểu luận nghiên cứu chuyên sâu này đã phác họa một cách toàn diện và sâu sắc bức tranh công nghệ của thuật toán tăng cường ảnh thiếu sáng đột phá **Zero-DCE**. Những đóng góp cốt lõi của nghiên cứu bao gồm:

1. Hệ thống hóa lịch sử phát triển của các công nghệ LLIE, vạch rõ ưu nhược điểm vật lý cảm biến và toán học của từng nhóm giải pháp từ truyền thống đến học sâu hiện đại.
2. Đưa ra chứng minh toán học chặt chẽ lần đầu tiên về tính đơn điệu tăng và tính bị chặn của họ đường cong LE-curve phi tuyến thích ứng - nền tảng lý thuyết bảo toàn cấu trúc tương phản tự nhiên của ảnh đầu ra.
3. Phân tích chi tiết triết lý thiết kế và công thức toán học của bốn hàm mất mát không tham chiếu tự giám sát độc đáo.
4. Hệ thống hóa và phân tích chuyên sâu cấu trúc mạng tích chập cực nhẹ và cơ chế học tập không tham chiếu.
5. Tổng hợp kết quả định lượng chi tiết trên các tập dữ liệu chuẩn, thảo luận thẳng thắn về các trường hợp thất bại thực tế và giải pháp ứng dụng hạ nguồn.

8.2 Đề xuất các hướng nghiên cứu mở rộng trong tương lai

Để khắc phục những hạn chế còn tồn tại của mô hình, chúng tôi đề xuất ba hướng nghiên cứu mở rộng đầy hứa hẹn trong tương lai:

- **Tích hợp module khử nhiễu liên hợp (Joint Denoising and Enhancement):** Nghiên cứu xây dựng một kiến trúc mạng nơ-ron hai nhánh song song tự giám sát, một nhánh ước lượng đường cong tăng sáng LE-curve và một nhánh ước lượng bản đồ nhiễu cảm biến để thực hiện lọc nhiễu đồng thời trong quá trình kéo sáng, giải quyết triệt để vấn đề phóng đại nhiễu hạt.
- **Cải tiến hàm mất mát hằng số màu thích ứng ngữ cảnh:** Thay thế giả thuyết Gray-World toàn cục bằng các thuật toán cân bằng màu sắc cục bộ thích ứng, giúp bảo toàn chính xác màu sắc nguyên bản của các cảnh vật đơn sắc tự nhiên.
- **Tối ưu hóa kiến trúc tự động hóa (Neural Architecture Search - NAS):** Áp dụng các thuật toán NAS để tự động tìm kiếm cấu trúc kết nối skip-connections tối ưu nhất cho DCE-Net nhằm đạt hiệu năng cao hơn nữa với số lượng tham số ít hơn.

Tài liệu

- [1] Guo, C., Li, C., Guo, J., Loy, C. C., Hou, J., Kwong, S., & Cong, R. (2020). Zero-reference deep curve estimation for low-light image enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 1780-1789).