



BÁO CÁO TIỂU LUẬN

MÔN HỌC: GIẢI THUẬT NÂNG CAO

ĐỀ TÀI:

**NGHIÊN CỨU VỀ THUẬT TOÁN ZERO-DCE:
TĂNG CƯỜNG ẢNH THIỂU SÁNG BẰNG PHƯƠNG PHÁP
ƯỚC LƯỢNG ĐƯỜNG CONG KHÔNG THAM CHIỀU**

Sinh viên thực hiện:	Đỗ Hữu Khang
Lớp:	KHOA HỌC MÁY TÍNH
Mã số sinh viên:	2580101060
Giảng viên hướng dẫn:	Trần Lê Anh

Mục lục

1	Giới thiệu	2
1.1	Tầm quan trọng của Tăng cường Ảnh Thiếu sáng	2
1.2	Hạn chế của các Phương pháp Truyền thống	2
1.3	Thách thức của Học sâu có Giám sát	3
2	Các công trình liên quan	3
2.1	Phương pháp dựa trên mô hình toán học	3
2.2	Học sâu không tham chiếu và GAN	3
3	Kiến trúc và Lý thuyết của Zero-DCE	3
3.1	Đường cong tăng cường ánh sáng (LE-curve)	3
3.1.1	Định nghĩa toán học	4
3.1.2	Cấu trúc bậc cao thông qua lặp lại	4
3.1.3	Ví dụ minh họa quá trình tăng cường	4
3.1.4	Khôi phục về không gian màu RGB 8-bit	6
3.2	Mạng thần kinh DCE-Net	6
3.2.1	Chi tiết kiến trúc	6
4	Phân tích Sâu về các Hàm Mất mát	7
4.1	Hàm mất mát nhất quán không gian (L_{spa})	7
4.2	Hàm mất mát kiểm soát phơi sáng (L_{exp})	7
4.3	Hàm mất mát hằng số màu sắc (L_{col})	7
4.4	Hàm mất mát độ mượt ánh sáng (L_{tv})	8
5	Kết quả Thực nghiệm và Thảo luận	8
5.1	Đánh giá Định lượng	8
5.2	Tốc độ xử lý và Khả năng ứng dụng	8
5.3	Phân tích Đạo hàm và Sự Hội tụ	8
6	Phân tích Chuyên sâu và Các Góc nhìn Mới	9
6.1	Tại sao 7 lớp tích chập?	9
6.2	Vấn đề về Nhiều và Khử nhiễu	9
7	Kết luận	9

Tóm tắt nội dung

Tăng cường hình ảnh trong điều kiện thiếu sáng (Low-Light Image Enhancement - LLIE) là một thách thức quan trọng trong lĩnh vực thị giác máy tính. Các phương pháp học sâu truyền thống thường dựa trên việc huấn luyện có giám sát với các cặp hình ảnh thiếu sáng và ảnh chuẩn (ground-truth), điều này gây ra khó khăn lớn trong việc thu thập dữ liệu thực tế. Bài báo này trình bày chi tiết về Zero-DCE (Zero-Reference Deep Curve Estimation), một phương pháp tiếp cận đột phá không cần dữ liệu tham chiếu. Zero-DCE coi bài toán tăng cường ánh sáng là bài toán ước lượng các đường cong điều chỉnh ánh sáng đặc thù cho từng điểm ảnh thông qua một mạng thần kinh tích chập nhẹ (DCE-Net). Chúng tôi phân tích sâu về cơ sở lý thuyết của các đường cong tăng cường (LE-curve), kiến trúc mạng, và bộ bốn hàm mất mát không tham chiếu độc đáo. Kết quả thực nghiệm cho thấy Zero-DCE đạt được hiệu suất vượt trội về cả chất lượng ảnh lẫn tốc độ xử lý, mở ra khả năng ứng dụng thời gian thực trên các thiết bị di động.

1 Giới thiệu

1.1 Tầm quan trọng của Tăng cường Ảnh Thiếu sáng

Trong kỷ nguyên kỹ thuật số, hình ảnh và video đóng vai trò quan trọng trong giao tiếp, giám sát, và các hệ thống tự hành. Tuy nhiên, việc thu nhận hình ảnh trong điều kiện ánh sáng yếu (như ban đêm, trong nhà, hoặc trong môi trường có độ tương phản cao) thường dẫn đến chất lượng ảnh kém. Các vấn đề phổ biến bao gồm:

- **Độ tương phản thấp:** Các chi tiết bị chìm trong bóng tối, khó phân biệt.
- **Nhiều hạt (Noise):** Do cảm biến phải đẩy ISO lên cao, tạo ra các hạt màu không mong muốn.
- **Sai lệch màu sắc:** Ánh sáng yếu làm cảm biến không ghi nhận chính xác phổ màu.

Việc giải quyết những vấn đề này không chỉ cải thiện thẩm mỹ mà còn là tiền đề cho các hệ thống AI khác hoạt động ổn định hơn.

1.2 Hạn chế của các Phương pháp Truyền thống

Trước khi học sâu bùng nổ, các kỹ thuật như *Histogram Equalization* (HE) và *Gamma Correction* là những lựa chọn hàng đầu. Mặc dù đơn giản, chúng thường gây ra hiện tượng tăng cường quá mức (over-enhancement), làm mất chi tiết ở những vùng vốn đã đủ sáng. Lý thuyết Retinex cũng được áp dụng rộng rãi nhưng đòi hỏi các giả định phức tạp về sự phân tách ánh sáng và phản xạ, vốn không phải lúc nào cũng đúng trong thực tế.

1.3 Thách thức của Học sâu có Giám sát

Các mô hình như RetinexNet hay LLNet yêu cầu tập dữ liệu huấn luyện gồm các cặp ảnh (tối - sáng). Việc tạo ra tập dữ liệu này đối mặt với hai rào cản:

1. **Sự sai lệch pixel:** Việc giữ camera đứng yên tuyệt đối để chụp hai bức ảnh ở hai mức phơi sáng khác nhau là rất khó.
2. **Tính chủ quan của ảnh chuẩn:** Một bức ảnh "sáng đẹp" thường mang tính cảm tính, dẫn đến việc mô hình có thể bị thiên kiến theo tập dữ liệu cụ thể.

Zero-DCE ra đời để phá bỏ những rào cản này bằng cách tự học từ chính các bức ảnh thiếu sáng mà không cần bất kỳ sự hướng dẫn nào từ ảnh chuẩn.

2 Các công trình liên quan

2.1 Phương pháp dựa trên mô hình toán học

Nhiều nghiên cứu tập trung vào việc ước lượng bản đồ chiếu sáng (illumination map). LIME (Low-light Image Enhancement) là một ví dụ điển hình, nơi tác giả tối ưu hóa một bản đồ ánh sáng dựa trên cấu trúc của ảnh đầu vào. Tuy nhiên, các phương pháp này thường dựa trên các ràng buộc thủ công (hand-crafted priors) nên thiếu tính linh hoạt khi gặp các bối cảnh ánh sáng phức tạp.

2.2 Học sâu không tham chiếu và GAN

Để loại bỏ nhu cầu về ảnh cặp, một số nghiên cứu sử dụng GAN (Generative Adversarial Networks). Ví dụ, EnGAN sử dụng bộ phân biệt (discriminator) để ép ảnh đầu ra trông giống như các bức ảnh có ánh sáng tốt. Tuy nhiên, GAN rất khó huấn luyện, tiêu tốn tài nguyên và đôi khi tạo ra các chi tiết giả (artifacts). Zero-DCE đi theo một hướng khác: ổn định hơn, nhẹ hơn và dễ giải thích hơn.

3 Kiến trúc và Lý thuyết của Zero-DCE

3.1 Đường cong tăng cường ánh sáng (LE-curve)

Khác với các mạng thần kinh thông thường cố gắng dự đoán trực tiếp giá trị RGB của điểm ảnh, Zero-DCE dự đoán một đường cong. Đường cong này được lấy cảm hứng từ tính năng "Curves" trong các phần mềm đồ họa.

3.1.1 Định nghĩa toán học

Hàm tăng cường cơ bản được định nghĩa là:

$$LE(I(x); \alpha) = I(x) + \alpha I(x)(1 - I(x)) \quad (1)$$

Trong đó $I(x)$ là giá trị điểm ảnh đầu vào đã được chuẩn hóa về đoạn $[0, 1]$. Cụ thể, các giá trị kênh màu của điểm ảnh gốc (thường ở định dạng 8-bit có giá trị nguyên trong đoạn $[0, 255]$) sẽ được đưa về đoạn $[0, 1]$ theo công thức:

$$I(x) = \frac{x_{\text{RGB}}}{255} \quad (2)$$

với $x_{\text{RGB}} \in [0, 255]$ là giá trị số của kênh màu (Red, Green, Blue) tại điểm ảnh cần xét. Tham số α là trọng tâm của mô hình. Khi α dương, giá trị điểm ảnh sẽ được đẩy lên cao hơn. Đặc biệt, tại các giá trị $I(x)$ gần 0 hoặc 1, thành phần $\alpha I(x)(1 - I(x))$ sẽ nhỏ, giúp bảo toàn các vùng đen tuyệt đối và trắng tuyệt đối.

3.1.2 Cấu trúc bậc cao thông qua lặp lại

Để mô hình hóa các biến đổi phức tạp, Zero-DCE áp dụng đường cong này lặp lại n lần:

$$I_n(x) = I_{n-1}(x) + \alpha_n I_{n-1}(x)(1 - I_{n-1}(x)) \quad (3)$$

Mỗi bước lặp n sử dụng một bản đồ tham số α_n khác nhau. Với $n = 8$, hàm cuối cùng có bậc là $2^8 = 256$, đủ sức mạnh để khôi phục ánh sáng ngay cả trong những điều kiện khắc nghiệt nhất.

3.1.3 Ví dụ minh họa quá trình tăng cường

Để hiểu rõ hơn về cách LE-curve hoạt động và bảo toàn các vùng sáng/tối tuyệt đối, chúng ta hãy xem xét một ví dụ với 3 điểm ảnh ban đầu có giá trị kênh màu RGB lần lượt là Đen (0, 0, 0), Trắng (255, 255, 255), và Xám tối (51, 51, 51).

Trước khi đưa vào công thức tăng cường, các giá trị này được chuẩn hóa về khoảng $[0, 1]$ bằng cách chia giá trị của từng kênh màu cho 255.

Vì đây là các điểm ảnh đơn sắc hoặc xám (có giá trị của ba kênh màu R, G, B trùng nhau), ta có thể đại diện giá trị tính toán thông qua một kênh duy nhất nhằm đơn giản hóa minh họa:

- **Đen** ($R = 0, G = 0, B = 0$): Do điểm ảnh đen hoàn toàn có giá trị cường độ trên cả ba kênh bằng 0, ta có giá trị đầu vào chuẩn hóa tương ứng là $I_0 = \frac{0}{255} = 0.0$.

- **Trắng** ($R = 255, G = 255, B = 255$): Do điểm ảnh trắng hoàn toàn đạt mức cường độ tối đa bằng 255 trên cả ba kênh, ta thu được giá trị chuẩn hóa là $I_0 = \frac{255}{255} = 1.0$.
- **Xám tối** ($R = 51, G = 51, B = 51$): Do điểm ảnh xám tối có giá trị kênh màu bằng 51, ta thu được giá trị chuẩn hóa là $I_0 = \frac{51}{255} = 0.2$.

Lưu ý đối với ảnh màu: Đối với các điểm ảnh có màu sắc bất kỳ (khi các kênh R, G, B có giá trị khác nhau), ví dụ điểm ảnh có mã màu RGB là (30, 24, 60), thuật toán sẽ chuẩn hóa độc lập từng kênh màu trước khi đưa vào tính toán:

- Kênh Red ($R = 30$): $I_{0,R} = \frac{30}{255} \approx 0.118$
- Kênh Green ($G = 24$): $I_{0,G} = \frac{24}{255} \approx 0.094$
- Kênh Blue ($B = 60$): $I_{0,B} = \frac{60}{255} \approx 0.235$

Sau đó, mỗi kênh $I_{0,R}, I_{0,G}, I_{0,B}$ sẽ được tăng cường song song và độc lập bằng các tham số $\alpha_R, \alpha_G, \alpha_B$ tương ứng được dự đoán bởi mạng thần kinh.

Giả sử mạng DCE-Net dự đoán tham số $\alpha = 0.5$ (hệ số kéo sáng) cho cả 3 điểm ảnh đơn sắc ở trên và chúng ta thực hiện tính toán qua 3 vòng lặp ($n = 3$):

- **Điểm ảnh Đen** ($I_0 = 0.0$):
 - Lần lặp 1: $I_1 = 0.0 + 0.5 \times 0.0 \times (1 - 0.0) = 0.0$
 - Kết quả sau 3 vòng lặp vẫn là 0.0. Tính chất này cho thấy thuật toán không làm "xám hóa" các vùng tối đen hoàn toàn trong ảnh gốc, giúp bảo toàn độ tương phản tự nhiên của vật thể.
- **Điểm ảnh Trắng** ($I_0 = 1.0$):
 - Lần lặp 1: $I_1 = 1.0 + 0.5 \times 1.0 \times (1 - 1.0) = 1.0 + 0 = 1.0$
 - Kết quả sau 3 vòng lặp vẫn là 1.0. Nhờ thiết kế toán học khéo léo, hàm sẽ triệt tiêu phần tăng cường khi $I(x)$ tiến tới 1, giúp thuật toán tự động tránh hiện tượng lóa sáng (over-exposure) ở các nguồn sáng.
- **Điểm ảnh Xám tối** ($I_0 = 0.2$):
 - Lần lặp 1: $I_1 = 0.2 + 0.5 \times 0.2 \times (1 - 0.2) = 0.2 + 0.08 = 0.28$
 - Lần lặp 2: $I_2 = 0.28 + 0.5 \times 0.28 \times (1 - 0.28) = 0.28 + 0.5 \times 0.28 \times 0.72 = 0.28 + 0.1008 = 0.3808$
 - Lần lặp 3: $I_3 = 0.3808 + 0.5 \times 0.3808 \times (1 - 0.3808) \approx 0.3808 + 0.5 \times 0.3808 \times 0.6192 \approx 0.3808 + 0.1179 \approx 0.4987$

3.1.4 Khôi phục về không gian màu RGB 8-bit

Sau khi thu được giá trị cường độ chuẩn hóa ở vòng lặp cuối cùng (ở đây là I_3), thuật toán thực hiện khôi phục điểm ảnh về không gian màu 8-bit ban đầu ($[0, 255]$) bằng cách nhân với 255 và làm tròn đến số nguyên gần nhất:

$$x_{\text{RGB, final}} = \text{round}(I_n(x) \times 255) \quad (4)$$

Áp dụng công thức khôi phục này cho 3 điểm ảnh trong ví dụ trên:

- **Điểm ảnh Đen:** $x_{\text{RGB, final}} = \text{round}(0.0 \times 255) = 0 \rightarrow$ Điểm ảnh khôi phục là Đen $(0, 0, 0)$.
- **Điểm ảnh Trắng:** $x_{\text{RGB, final}} = \text{round}(1.0 \times 255) = 255 \rightarrow$ Điểm ảnh khôi phục là Trắng $(255, 255, 255)$.
- **Điểm ảnh Xám tối:** $x_{\text{RGB, final}} = \text{round}(0.4987 \times 255) = \text{round}(127.1685) \approx 127 \rightarrow$ Điểm ảnh khôi phục là Xám trung tính $(127, 127, 127)$.

Thông qua ví dụ toán học trên, ta thấy điểm ảnh xám tối ban đầu từ mức màu $(51, 51, 51)$ đã được tăng cường độ sáng lên thành màu xám sáng hơn nhiều là $(127, 127, 127)$ một cách mượt mà và tiệm tiến qua từng bước. Trong khi đó, các giới hạn đen/trắng hai đầu không hề bị phá vỡ hay bị cắt cụt (clipping).

Trong cấu hình thực tế của mô hình gốc, Zero-DCE lặp lại $n = 8$ lần với các giá trị α_n khác nhau được dự đoán độc lập tại mỗi vòng lặp, tạo ra quỹ đạo kéo sáng cực kỳ tinh tế và phức tạp, thích nghi với từng vùng sáng tối khác nhau trên ảnh.

3.2 Mạng thần kinh DCE-Net

DCE-Net là một mạng tích chập hoàn toàn (FCN) với nhiệm vụ duy nhất: từ ảnh đầu vào I , tạo ra các bản đồ tham số $\mathcal{A} = \{\alpha_1, \alpha_2, \dots, \alpha_n\}$.

3.2.1 Chi tiết kiến trúc

Mạng gồm 7 lớp tích chập đối xứng:

- **Lớp 1-6:** Mỗi lớp sử dụng 32 filter 3×3 với activation ReLU.
- **Lớp 7:** Lớp cuối cùng sử dụng hàm Tanh để đảm bảo $\alpha \in [-1, 1]$.
- **Skip Connections:** Nhằm giữ lại thông tin không gian, đầu ra của các lớp được nối lại với nhau theo cặp (1-6, 2-5, 3-4).

Kiến trúc này đảm bảo rằng mỗi pixel trong bản đồ α đều được hưởng lợi từ thông tin ngữ cảnh xung quanh nó, dẫn đến sự điều chỉnh ánh sáng nhất quán.

4 Phân tích Sâu về các Hàm Mất mát

Đây là phần quan trọng nhất giúp Zero-DCE có thể huấn luyện không tham chiếu. Tổng hàm mất mát là sự kết hợp của 4 thành phần:

$$L_{total} = w_{spa}L_{spa} + w_{exp}L_{exp} + w_{col}L_{col} + w_{tv}L_{tv} \quad (5)$$

4.1 Hàm mất mát nhất quán không gian (L_{spa})

Một bức ảnh tăng cường tốt phải giữ được cấu trúc biên của vật thể. L_{spa} đo lường sự chênh lệch giữa các điểm ảnh lân cận trong ảnh đầu vào và ảnh đầu ra:

$$L_{spa} = \frac{1}{K} \sum_{i=1}^K \sum_{j \in \Omega(i)} (|Y_i - Y_j| - |I_i - I_j|)^2 \quad (6)$$

Nếu điểm ảnh i sáng hơn điểm ảnh j trong ảnh gốc, nó cũng phải sáng hơn trong ảnh kết quả với một tỷ lệ tương ứng.

4.2 Hàm mất mát kiểm soát phơi sáng (L_{exp})

Để tránh ảnh bị cháy sáng hoặc vẫn còn quá tối, L_{exp} ép độ sáng trung bình của các vùng cục bộ về một giá trị mục tiêu $E \approx 0.6$.

$$L_{exp} = \frac{1}{M} \sum_{k=1}^M |\bar{Y}_k - E| \quad (7)$$

Việc tính toán trên các cửa sổ cục bộ (16×16) thay vì toàn bộ ảnh giúp mô hình xử lý tốt các tình huống ánh sáng không đồng đều (Mixed lighting).

4.3 Hàm mất mát hằng số màu sắc (L_{col})

Dựa trên giả định Gray-world, L_{col} ép các kênh màu R, G, B có cường độ trung bình tương đương nhau, giúp loại bỏ các hiện tượng ám màu:

$$L_{col} = \sum_{\forall (p,q) \in \{(R,G), (R,B), (G,B)\}} (\mu_p - \mu_q)^2 \quad (8)$$

4.4 Hàm mất mát độ mượt ánh sáng (L_{tv})

Để đảm bảo bản đồ tham số α không bị nhiễu và thay đổi quá đột ngột (gây ra hiện tượng nhiễu khối), hàm Total Variation được áp dụng:

$$L_{tv} = \frac{1}{N} \sum_{n=1}^N \sum_{c \in \{R, G, B\}} (\|\nabla_x \alpha_{n,c}\|_2^2 + \|\nabla_y \alpha_{n,c}\|_2^2) \quad (9)$$

5 Quá trình Huấn luyện Mô hình

Quá trình huấn luyện của mô hình Zero-DCE diễn ra theo một chu trình khép kín và không cần tham chiếu (zero-reference), bao gồm bốn bước chính sau:

5.1 Chuẩn bị dữ liệu (Data Preparation)

Mô hình Zero-DCE không cần các cặp ảnh "một tối - một sáng của cùng một khung cảnh" (paired data) để huấn luyện. Điều này giúp tiết kiệm rất nhiều công sức thu thập và xử lý dữ liệu. Người dùng chỉ cần cung cấp cho mô hình một tập hợp các bức ảnh đầu vào với các điều kiện ánh sáng khác nhau (chủ yếu là ảnh thiếu sáng).

5.2 Quá trình lan truyền xuôi (Forward Pass)

Trong bước lan truyền xuôi:

- Bức ảnh thiếu sáng được đưa vào mạng CNN (DCE-Net).
- Mạng sẽ tính toán và xuất ra một tập hợp các "bản đồ tham số" (Curve Parameters, ký hiệu là α).
- Hệ thống sẽ lấy bức ảnh gốc, kết hợp với các tham số α này thông qua một phương trình toán học để uốn nắn ánh sáng theo nhiều vòng lặp (thường cấu hình là 8 vòng lặp - iterations). Kết quả cuối cùng thu được là một bức ảnh đã được tăng cường độ sáng (Enhanced Image).

5.3 Đánh giá chất lượng bằng Hàm mất mát (Loss Functions)

Vì không có ảnh chuẩn (ground-truth) để so sánh điểm ảnh với điểm ảnh (pixel-to-pixel), sự thành bại trong huấn luyện của Zero-DCE phụ thuộc hoàn toàn vào 4 hàm mất mát không giám sát được thiết kế đặc thù để tự đánh giá chất lượng bức ảnh vừa tạo ra:

- **Hàm kiểm soát phơi sáng (Exposure Control Loss - L_{exp}):** Mạng sẽ chia bức ảnh ra thành các vùng nhỏ cục bộ và đo độ sáng trung bình. Nó ép độ sáng này tiến về một mức lý tưởng (thường cài đặt bằng 0.6). Nếu vùng nào quá chói (overexposed) hoặc vẫn quá tối (underexposed), giá trị lỗi sẽ tăng lên.
- **Hàm hằng số màu (Color Constancy Loss - L_{col}):** Khi tăng sáng, ảnh rất dễ bị ám màu hoặc lệch tông. Dựa trên giả thuyết "Thế giới xám" (Grey-world assumption), hàm này ép giá trị trung bình của ba kênh màu Đỏ, Xanh lá, Xanh dương (R, G, B) trong toàn bức ảnh không bị lệch nhau quá nhiều, giúp màu sắc giữ được sự tự nhiên.
- **Hàm độ mượt của ánh sáng (Illumination Smoothness Loss - L_{tv_A}):** Nếu tham số uốn cong ánh sáng của một điểm ảnh quá khác biệt so với điểm ảnh ngay cạnh nó, bức ảnh sẽ bị nhiễu hạt hoặc xuất hiện các vết sáng gắt (artifacts). Hàm này phạt sự thay đổi đột ngột của tham số α giữa các vùng lân cận, giúp ánh sáng lan tỏa một cách mượt mà.
- **Hàm nhất quán không gian (Spatial Consistency Loss - L_{spa}):** Hàm này so sánh sự chênh lệch (gradient) giữa các vùng trong ảnh gốc và ảnh đầu ra. Nó đảm bảo rằng việc tăng sáng không làm mất đi các chi tiết, ranh giới vật thể và cấu trúc tổng thể ban đầu của bức ảnh.

5.4 Cập nhật trọng số (Backpropagation)

Tổng của 4 hàm mất mát trên sẽ tạo thành một Lỗi Tổng (Total Loss). Mạng sẽ sử dụng thuật toán tối ưu hóa (thường là Adam Optimizer) để tính toán đạo hàm và thực hiện lan truyền ngược (Backpropagation). Quá trình này sẽ từ từ điều chỉnh các trọng số (weights) bên trong mạng lưới CNN ban đầu. Qua nhiều vòng lặp huấn luyện (epochs), mạng DCE-Net sẽ tự học được cách rút ra các bản đồ tham số α tối ưu nhất sao cho bức ảnh cuối cùng thỏa mãn cả 4 tiêu chí: sáng vừa đủ, màu sắc tự nhiên, không bị vỡ hạt hay nhiễu khối và giữ nguyên chi tiết cấu trúc.

6 Kết quả Thực nghiệm và Thảo luận

6.1 Đánh giá Định lượng

Trên tập dữ liệu LOL, Zero-DCE đạt kết quả ấn tượng dù không được huấn luyện trên đó. So với các phương pháp có giám sát, mặc dù chỉ số PSNR có thể thấp hơn một chút (do không tối ưu trực tiếp theo pixel), nhưng các chỉ số về chất lượng tự nhiên (NIQE, PI) lại vượt trội.

Bảng 1: So sánh tốc độ xử lý trên GPU NVIDIA RTX 2080Ti

Phương pháp	Độ phân giải	Thời gian (s)	FPS
RetinexNet	640×480	0.12	8.3
LIME	640×480	0.05	20.0
Zero-DCE	640×480	0.002	500.0

6.2 Tốc độ xử lý và Khả năng ứng dụng

Với tốc độ 500 FPS cho ảnh SD, Zero-DCE là ứng cử viên số một cho việc tăng cường video trực tiếp trên smartphone. Phiên bản Zero-DCE++ thậm chí còn nhẹ hơn, cho phép chạy trên các CPU yếu mà không cần GPU chuyên dụng.

6.3 Phân tích Đạo hàm và Sự Hội tụ

Đạo hàm của hàm LE-curve theo α là:

$$\frac{\partial LE(I; \alpha)}{\partial \alpha} = I(1 - I) \quad (10)$$

Biểu thức này luôn dương trong khoảng $(0, 1)$, điều này đảm bảo rằng quá trình gradient descent sẽ luôn tìm được hướng tối ưu để điều chỉnh độ sáng mà không gặp phải các điểm cực trị cục bộ phức tạp.

7 Phân tích Chuyên sâu và Các Góc nhìn Mới

7.1 Tại sao 7 lớp tích chập?

Tác giả đã thử nghiệm với nhiều độ sâu mạng khác nhau. Với ít hơn 5 lớp, mạng không đủ khả năng học các đặc trưng không gian phức tạp. Với nhiều hơn 10 lớp, hiệu suất cải thiện không đáng kể trong khi tốc độ giảm đi. 7 lớp là "điểm ngọt"(sweet spot) cân bằng giữa độ chính xác và tốc độ.

7.2 Vấn đề về Nhiều và Khử nhiễu

Một điểm yếu khách quan của Zero-DCE là nó không có cơ chế khử nhiễu. Trong ảnh thiếu sáng, nhiễu thường tập trung ở các vùng tối. Khi Zero-DCE kéo sáng các vùng này, nhiễu cũng bị phóng đại. Trong các phiên bản mở rộng (như Zero-DCE++), việc tích hợp thêm một lớp khử nhiễu nhẹ đã được xem xét để cải thiện chất lượng cuối cùng.

8 Kết luận

Zero-DCE đại diện cho một bước tiến quan trọng trong xử lý ảnh bằng học sâu. Bằng cách kết hợp tri thức toán học về đường cong với khả năng học đặc trưng của CNN, nó đã tạo ra một giải pháp vừa mạnh mẽ, vừa hiệu quả, vừa linh hoạt. Việc không phụ thuộc vào dữ liệu tham chiếu là chìa khóa để mô hình có thể thích nghi với vô vàn điều kiện ánh sáng thực tế trong tương lai.

Tài liệu

- [1] Guo, C., Li, C., Guo, J., Loy, C. C., Hou, J., Kwong, S., & Cong, R. (2020). Zero-reference deep curve estimation for low-light image enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 1780-1789).
- [2] Li, C., Guo, C., & Loy, C. C. (2021). Learning to enhance low-light images via zero-reference deep curve estimation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- [3] Wei, C., Wang, W., Yang, W., & Liu, Jiaying. (2018). Deep Retinex Decomposition for Low-Light Enhancement. In *BMVC*.
- [4] Guo, X., Li, Y., & Ling, H. (2016). LIME: Low-light image enhancement via illumination map estimation. *IEEE Transactions on Image Processing*, 26(2), 982-993.
- [5] Cai, J., Gu, S., & Zhang, L. (2018). Learning a deep single image contrast enhancer from multi-exposure images. *IEEE Transactions on Image Processing*, 27(4), 2049-2062.